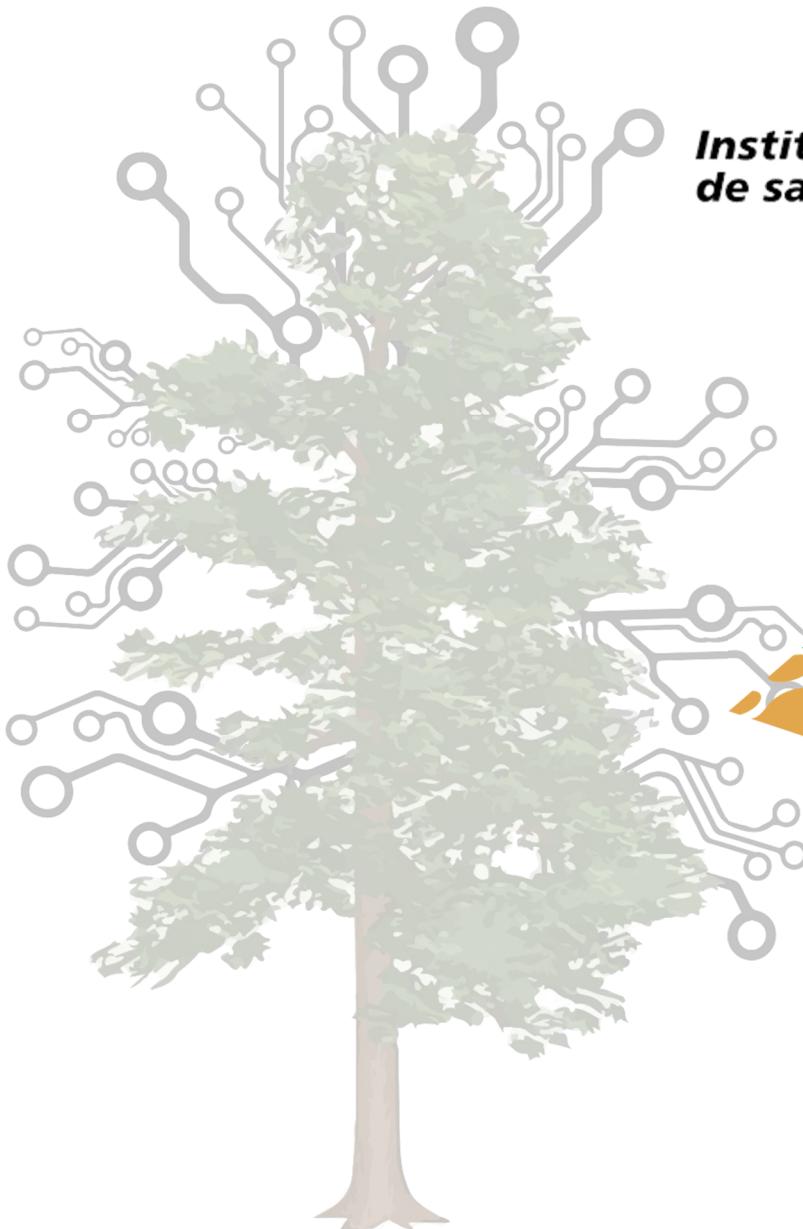


# Rapport Méthodologique

Cartographie de la canopée des six régions métropolitaines de recensement du Québec par apprentissage profond et données lidar



Présenté à

***Institut national  
de santé publique***

**Québec**

Ray Bustinza, M.Sc.

Céline Campagna, Ph.D.

Par :



**CERFO**

Centre d'enseignement et de recherche  
en foresterie de Sainte-Foy inc.

Batistin Bour, M.Sc.

Marc-Antoine Genest, M.Sc.

Camille Armellin, B.A.

Maryam Rashidfar, Ph.D.

Mathieu Varin, M.Sc.

Février 2022

Ce projet est financé dans le cadre de Plan d'action 2013-2020 sur les changements climatiques.

Mots-clés : canopée, régions métropolitaines de recensement du Québec, télédétection, traitement d'images, intelligence artificielle, apprentissage profond, lidar aéroporté.

Référence à citer :

Bour, B., Genest, M.-A., Armellin, C., Rashidfar, M. et Varin, M. 2022. Cartographie de la canopée des six régions métropolitaines de recensement du Québec par apprentissage profond et données lidar. Centre d'enseignement et de recherche en foresterie de Sainte-Foy inc. (CERFO). Rapport 2022-10. 59 pages.

## Résumé

La couverture végétale urbaine apporte un grand nombre d'avantages sociétaux, économiques et de santé publique. La cartographie et le suivi de la canopée, définie par la projection au sol de la végétation arbustive et arborescente, sont une donnée d'intérêt, autant pour les gestionnaires de territoires que pour les citoyens. Plusieurs villes d'Amérique du Nord possèdent une cartographie de leur canopée, mais les méthodes et paramètres considérés diffèrent. Considérant les avantages délivrés par les cartographies de canopée, l'INSPQ a souhaité doter le Québec d'une cartographie uniforme des principales zones habitées. Plusieurs méthodes ont déjà été mises en œuvre pour cartographier une canopée urbaine, toutes ayant en commun l'utilisation d'imagerie aérienne ou satellitaire, parfois combinée à des données lidar mesurant la hauteur de la végétation présente. Ces méthodes, bien qu'offrant des performances intéressantes, détiennent plusieurs limites avec notamment des problèmes d'alignement entre données d'imagerie et lidar ou par le coût engendré par l'acquisition d'images pour un grand territoire. Considérant les dernières avancées en intelligence artificielle (apprentissage profond) et la disponibilité de données lidar pour tout le Québec méridional, ce projet vise le développement d'un algorithme utilisant uniquement la donnée lidar pour cartographier la canopée et à appliquer cette méthode sur les six régions métropolitaines de recensement (RMR) du Québec. Les données lidar brutes ont été utilisées pour calculer plusieurs variables décrivant la structure verticale des points, à une résolution spatiale de 1 m. Une sélection des variables les plus pertinentes a été réalisée et celles-ci ont été utilisées dans un processus de développement itératif d'algorithmes d'apprentissage profond. Le modèle final montre d'excellentes performances de classification variable selon les RMR (précision globale entre 0,9559 et 0,9712 et coefficient de kappa allant de 0,8996 à 0,9393). Les indices de canopée prédits par RMR sont corrélés entre 97,5 et 99,6 % avec les indices calculés manuellement. Les prédictions réalisées par le modèle montrent une très bonne capacité de discernement des éléments présents, notamment en milieu urbain où une grande diversité de structures ressemble à de la végétation lorsqu'analysé uniquement avec des données lidar. Certaines erreurs ont toutefois été identifiées et concernent principalement des structures absentes des données d'entraînement (p. ex. bateaux) ou des structures présentant fréquemment de la végétation sous-jacente (p. ex. câbles électriques). La cartographie de toutes les RMR avec cette méthode permet d'effectuer des comparaisons entre plusieurs secteurs intra et inter RMR. Des pistes d'amélioration ont été identifiées pouvant être appliquées à plusieurs stades du processus de développement. Lors de l'actualisation des données lidar de la province du Québec, une mise à jour de la canopée par cette méthode pourra être réalisée.

## **Composition du comité de suivi**

Le comité de suivi du projet était constitué de :

- Centre d'Enseignement et de Recherche en Foresterie :  
Mathieu Varin – Chef du laboratoire de télédétection  
Batistin Bour – Chercheur en télédétection forestière  
Marc-Antoine Genest – Spécialiste en intelligence artificielle  
Emmanuelle Boulfroy – Chargée de projet en foresterie urbaine
- Université de Sherbrooke :  
Yacine Bouroubi – Professeur au département de géomatique appliquée
- Institut National de Santé Publique du Québec :  
Ray Bustinka – Conseiller scientifique  
Nathalie Gravel – Analyste en géomatique  
Pierre Gosselin – Conseiller scientifique
- Ministère de l'Environnement et de la Lutte contre les Changements Climatiques :  
Frédéric Morneau-Vaillencourt – Responsable de projets de recherche  
Véronique Parent-Lacharité – Conseillère en adaptation aux changements climatiques
- Ministère des Affaires municipales et de l'Habitation :  
Marion Vincens – Conseillère aux programmes en changement climatiques
- Union des Municipalités du Québec :  
Geneviève David Watson – Conseillère aux politiques (Changements climatiques et environnement)

# Table des matières

## Résumé

Composition du comité de suivi

Liste des figures

Liste des tableaux

1.	Introduction.....	1
2.	Territoire d'étude .....	2
3.	Données utilisées .....	3
3.1.	Données lidar.....	3
3.2.	Données de canopée de référence.....	7
4.	Méthodologie .....	8
4.1.	Calcul de variables lidar .....	10
4.2.	Réduction du nombre de variables lidar.....	10
4.2.1.	Choix de l'algorithme .....	11
4.2.2.	Sélection de variables .....	11
4.3.	Préparation des données .....	13
4.3.1.	Prétraitement des données .....	13
4.3.2.	Création des jeux de données initiaux .....	14
4.4.	Bonification du jeu de données de segmentation de la canopée (trois mètres et plus)	
	15	
4.4.1.	Théorie - Apprentissage non supervisé et par transfert .....	15
4.4.2.	Choix des zones pour élaboration du jeu de données .....	16
4.4.3.	Entraînement non supervisé et par transfert .....	17
4.4.4.	Apprentissage actif .....	18
4.5.	Création d'un jeu de données de segmentation de la canopée (deux mètres et plus)	
	19	
4.5.1.	Altération des données pour prédire à deux mètres et plus .....	19
4.5.2.	Apprentissage par transfert pour la prédiction automatique (deux mètres et plus)	
	20	
4.5.1.	Finition du jeu de données deux mètres et plus .....	21
4.6.	Ensemble de modèles .....	22
4.6.1.	Apprentissage actif à large étendue .....	22
4.6.2.	Choix des modèles pour l'ensemble .....	22
4.7.	Prédictions sur l'ensemble du territoire et fusion.....	23

4.7.1.	Extraction et préparation des imagettes pour la prédiction.....	23
4.7.2.	Segmentation automatique de la canopée.....	23
4.8.	Zones avec données lidar manquantes .....	23
4.9.	Validation des prédictions.....	24
5.	Performances des modèles.....	25
5.1.	Matrices d'erreurs.....	25
5.2.	Indices de canopée.....	32
6.	Discussion et conclusion.....	37
6.1.	Performances générales .....	37
6.2.	Erreurs de commission .....	43
6.3.	Erreurs d'omission .....	47
6.4.	Cas du modèle utilisant uniquement le modèle numérique de hauteur.....	50
6.5.	Effet de l'absence ou présence de feuilles lors des acquisitions .....	51
6.6.	Méthode de validation .....	53
6.7.	Exemple de comparaison de canopées .....	53
6.8.	Pistes d'amélioration .....	55
7.	Conclusion .....	56
8.	Références.....	57

## Liste des figures

Figure 1. Situation géographique des régions métropolitaines de recensement du Québec.....	3
Figure 2. Année d'acquisition des données lidar utilisées. ....	4
Figure 3. Présence de feuilles dans les arbres dans les acquisitions lidar utilisées. ....	5
Figure 4. Densité moyenne de points des données lidar utilisées.....	6
Figure 5. Zones ne contenant pas de données lidar brutes disponibles lors de la réalisation du projet et type de modèle appliqué.....	7
Figure 6. Extrait de la canopée de Montréal utilisé comme base de l'entraînement des modèles développés dans ce projet. ....	8
Figure 7. Schéma méthodologique des quatre grandes étapes réalisées pour produire la cartographie de la canopée des régions métropolitaines de recensement (RMR) du Québec. PSNR : proportion de signal sur bruit.....	9
Figure 8. Schéma d'un auto-encodeur développé pour la sélection de bandes hyperspectrales (extrait de Ahmad et al. (2017), p. 4).....	11
Figure 9. Illustration des variables sélectionnées pour prédire la canopée des régions métropolitaines de recensement. MNH : modèle numérique de hauteur.....	13
Figure 10. Exemple d'imagette créée pour le jeu d'entraînement initial. De gauche à droite : modèle numérique de hauteur, hauteur moyenne, écart-type et annotation manuelle de la canopée provenant de la donnée de référence. ....	14
Figure 11. Répartition des zones d'entraînement (entraînement + test) et de validation pour le jeu d'entraînement de la segmentation de la canopée (trois mètres et plus) sur l'île de Montréal. ....	15
Figure 12. Emplacement des données d'entraînement ajoutées en dehors de l'île de Montréal. ....	17
Figure 13. Schéma de l'algorithme non supervisé VICReg utilisé pour l'entraînement d'un encodeur (extrait de Bardes, Ponce, & LeCun, 2022, p. 2). ....	18
Figure 14. Apprentissage par transfert en récupérant l'encodeur préentraîné.....	18
Figure 15. Exemple d'une zone prédite avec de gauche à droite : le modèle numérique de hauteur, la prédiction de trois mètres et plus (vert), la prédiction de deux mètres et plus (bleu) et les corrections manuelles apportées (rouge). ....	20
Figure 16. Schéma de l'entraînement par transfert de l'algorithme de segmentation de la canopée (deux mètres et plus).....	21
Figure 17. Schéma de la structure du HRNet (extrait de Wang et al. (2019), p. 3). ....	21
Figure 18. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Gatineau. ....	26
Figure 19. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Québec.....	27
Figure 20. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Montréal. ....	28
Figure 21. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Sherbrooke. ....	29
Figure 22. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Saguenay. ....	30

Figure 23. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Trois-Rivières.....	31
Figure 24. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) des zones utilisant uniquement le modèle numérique de hauteur comme variable. ....	32
Figure 25. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Gatineau.	
.....	33
Figure 26. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Québec.	
.....	34
Figure 27. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Montréal.	
.....	34
Figure 28. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Sherbrooke.	
.....	35
Figure 29. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Saguenay.	
.....	35
Figure 30. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Trois-Rivières.....	36
Figure 31. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour les secteurs utilisant uniquement le M NH comme variable prédictive. ....	36
Figure 32. Comparaison entre les indices de canopées de référence et prédis par le modèle, pour les acquisitions lidar réalisées lors de la présence et absence de feuilles.....	37
Figure 33. Illustration avec le modèle numérique de hauteur et l'image aérienne de la capacité d'identification de canopée en milieu urbain présentant différentes structures de hauteur supérieure à deux mètres. ....	39
Figure 34. Comparaison dans la ville de Montréal entre images aériennes, modèles numérique de hauteur lidar 2015, canopée 2015 produite par la ville de Montréal et les prédictions du modèle par apprentissage profond. ....	40
Figure 35. Illustration avec le modèle numérique de hauteur et l'image aérienne de la capacité de discernement de structures de non-canopée en milieu boisé. ....	41
Figure 36. Comparaison dans la ville de Québec entre images aériennes, modèle numérique de hauteur lidar 2017, canopée 2021 produite avec des images satellites pour la ville de Québec et les prédictions du modèle par apprentissage profond; en blanc, la canopée prédictive. ....	42
Figure 37. Illustration avec le modèle numérique de hauteur et l'image aérienne d'erreurs de commission relevées (I. Véhicules récréatifs, II. Groupement de véhicules, III. Câbles électriques).....	45
Figure 38. Illustration des étapes d'apprentissage actif réalisées pour réduire les erreurs de commission associées au réseau de distribution d'électricité. MNH : modèle numérique de hauteur. ....	46

Figure 39. Exemples de commission sur des pylônes du réseau de distribution d'électricité, en blanc la canopée prédictive.....	47
Figure 40. Illustration avec le modèle numérique de hauteur (MNH) et l'image aérienne d'erreurs d'omission pouvant apparaître dans les boisés diffus. ....	49
Figure 41. Délimitation d'arbres uniques dans plusieurs configurations : I. Arbre dont la délimitation est trop contrainte (lidar avec feuilles) ; II. Arbre correctement délimité (lidar avec feuilles) ; III. Arbre dont la délimitation est trop contrainte (lidar sans feuille) ; IV. Arbre correctement délimité (lidar sans feuille). .....	50
Figure 42. Comparaison de modèles numériques de hauteur calculés sur l'île de Montréal avec des données lidar acquises sans et avec feuilles. ....	52
Figure 43. Comparaison de la superficie de canopée issue des données produites par la ville de Montréal et par ce projet utilisant l'apprentissage profond, pour l'arrondissement de Lachine à Montréal.....	54
Figure 44. Illustration d'anomalies identifiées dans la canopée produite par la ville de Montréal en 2015 le long des rives. ....	54

## Liste des tableaux

Tableau 1. Estimation de la population des régions métropolitaines de recensement du Québec (extrait de Statistiques Québec, 2021).....	2
Tableau 2. Liste et description des variables calculées par pixels à partir des nuages de points bruts. .....	10
Tableau 3. Résultats du PSNR (proportion de signal sur bruit) pour la reconstruction des zones bruitées en validation lors de la sélection des variables lidar. Les lignes vertes indiquent les variables sélectionnées et les lignes jaunes indiquent les variables testées en segmentation, mais rejetées lors des tests préliminaires.....	12
Tableau 4. Résultats de la segmentation de la canopée sur les tuiles tests. En jaune les tuiles qui ont eu des corrections manuelles et en rouge la tuile qui a été rejetée. ....	19
Tableau 5. Paramètres des trois modèles de l'ensemble. .....	23
Tableau 6. Superficie de canopée et indice de canopée global par RMR.....	38

## 1. Introduction

La végétation en milieu urbain joue de nombreux rôles importants. Elle permet de réduire les effets dommageables sur notre environnement, notamment en diminuant la température ambiante des villes, en réduisant la présence de gaz polluants dans l'air et en filtrant les particules fines et aérosols en suspension dans l'air (Favaro *et al.*, 2020; Grilli et Sacchelli, 2020). Le lien entre santé publique et présence d'arbres a été documenté depuis plusieurs décennies et montre plusieurs avantages à la présence d'arbres dans les zones urbaines (Heisler, 2010; Kondo *et al.*, 2018; Nowak *et al.*, 2014). Les arbres en milieu urbain remplissent également de nombreux autres services écologiques, sociaux et économiques, en contribuant par exemple au maintien de la biodiversité, à la richesse esthétique des paysages d'une ville et même en augmentant la valeur foncière des propriétés (Kardan *et al.*, 2017; Lessard et Boulfroy, 2008).

Considérant les gains et avantages que procure la végétation en milieu urbain, de plus en plus de villes ont le souci d'améliorer la qualité de vie de leurs citoyens, par la mise en place de mesures visant à augmenter ou protéger la couverture arborescente sur leur territoire. Dans ce contexte, des outils d'évaluation de la présence de couverture arborescente et du suivi de son évolution dans le temps s'avèrent fort utiles. De tels outils permettent non seulement de prioriser les secteurs de plantation où le couvert arborescent est jugé insuffisant, mais aussi de fixer des cibles à atteindre en termes de présence de couvert arborescent, de quantifier les efforts déployés pour le maintien et la bonification du couvert arborescent, et aussi d'obtenir un portrait qui peut être comparé à celui d'autres villes nord-américaines.

L'Institut national de santé publique du Québec (INSPQ) a souhaité, avec la réalisation de ce projet, établir une référence pour toutes les régions métropolitaines de recensement (RMR) du Québec afin d'assurer le suivi de l'indice de canopée dans le temps. La canopée se définit comme la projection au sol de la cime (couronne) des arbres (incluant les feuilles, les branches et le tronc), qui est visible depuis le ciel (Miller *et al.*, 1997). Dans le cadre de ce projet, la végétation incluse dans la canopée a été élargie à toute végétation d'une hauteur minimum de deux mètres, incluant donc de petits arbres et des haies. Plusieurs grandes villes nord-américaines disposent déjà d'une cartographie de leur canopée produite avec différentes méthodes et leur permettent d'avoir un indice de canopée (Montréal : 20 %, Québec : 32 %, Toronto 28 %, New-York : 21 %, Baltimore : 28 %, etc.).

Traditionnellement, la canopée est identifiée grâce à de l'imagerie satellite haute résolution (30 cm) ou aérienne (Varin *et al.*, 2020a; Varin et Boulfroy, 2014), parfois combinée à une information de hauteur issue de données lidar (MacFaden *et al.*, 2012). L'imagerie, par le biais d'indices de végétation tels que le NDVI, est très performante pour identifier la présence de végétation, cependant l'information sur la hauteur des éléments présents dans les images fait défaut ce qui ne permet pas, à première vue, de distinguer un arbre d'une zone de végétation basse (p. ex. des arbustes). Pour pallier cette lacune, l'utilisation d'approches de segmentation d'objet peut fournir une estimation de la hauteur et ainsi écarter la végétation basse. Les données lidar sont souvent utilisées en combinaison avec l'imagerie puisque ces données fournissent une information sur la hauteur des éléments. Sa combinaison avec l'imagerie peut

présenter un défi en soi, notamment à cause de la présence de décalages dans les données, lorsque comparées avec l'imagerie ou à cause d'une date d'acquisition différente.

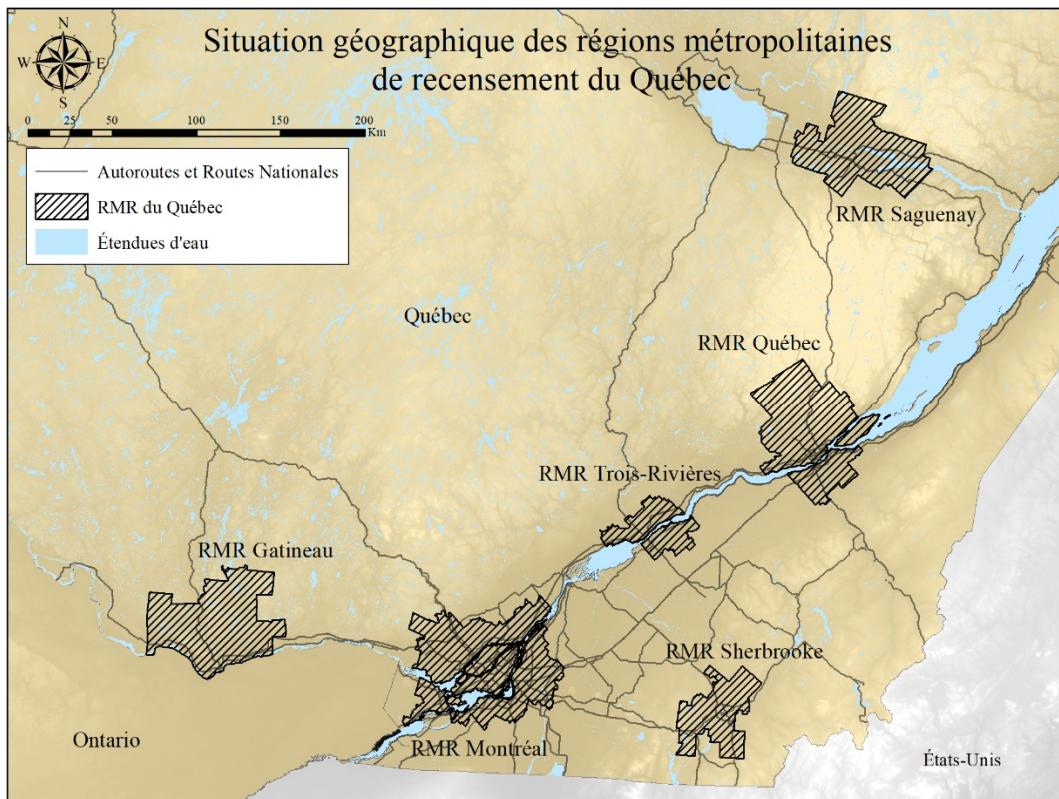
Dans le cadre de ce projet, l'utilisation d'imagerie satellitaire aurait impliqué plusieurs contraintes puisque l'acquisition de données pour couvrir toutes les RMR représente un coût non négligeable et que la présence de nuages dans les images aurait limité la cartographie de certains secteurs. Des images aériennes seraient moins limitantes à ce niveau, mais le décalage des dates d'acquisition représente un défi majeur et ne permettrait pas d'obtenir un niveau de précision satisfaisant. Des données lidar ont toutefois été acquises pour l'ensemble du Québec méridional depuis les dernières années (Leboeuf *et al.*, 2015). Au cours de celles-ci, les algorithmes d'apprentissage profond, une branche de l'intelligence artificielle, sont devenus de plus en plus performants dans des tâches de télédétection (Maxwell *et al.*, 2021). Ces approches ont montré une très bonne capacité à identifier des structures d'intérêt (Bour *et al.*, 2021; Genest *et al.*, 2021). De plus, les approches d'apprentissage profond excellent lors de l'utilisation d'un grand volume de données, de par leur capacité à identifier une variable pertinente parmi beaucoup d'autres (Zhang *et al.*, 2018). L'application de cette technique pour cartographier la canopée a déjà été réalisée (Timilsina *et al.*, 2020; Varin *et al.*, 2020b), mais repose soit uniquement sur l'imagerie, soit en combinaisons avec des données lidar. À notre connaissance, aucune méthode n'a utilisé uniquement le lidar comme données pour cartographier la canopée urbaine. Considérant les défis liés à l'acquisition d'images dans toutes les RMR, que des données lidar soient déjà disponibles et l'état de l'art en matière d'apprentissage profond, le développement d'un algorithme d'apprentissage profond pour la cartographie de la canopée utilisant uniquement des variables issues du lidar a été la méthode privilégiée pour mener à bien le mandat confié par l'INSPQ.

## 2. Territoire d'étude

Les six RMR du Québec ont été sélectionnées pour réaliser la cartographie de la canopée. Ces RMR regroupent la majorité de la population du Québec et couvrent un total de 16 403 km<sup>2</sup>. Le Tableau 1 montre la répartition de la population et de la superficie par RMR. La Figure 1 illustre la localisation des RMR du Québec.

Tableau 1. Estimation de la population des régions métropolitaines de recensement du Québec (extrait de Statistiques Québec, 2021).

Région métropolitaine de recensement	Population estimée en 2021	Superficie (km <sup>2</sup> )
Gatineau	351 450	3267
Québec	836 837	3404
Montréal	4 342 213	4301
Sherbrooke	227 408	1526
Saguenay	163 583	2853
Trois-Rivières	164 973	1052



*Figure 1. Situation géographique des régions métropolitaines de recensement du Québec.*

### 3. Données utilisées

#### 3.1. Données lidar

Les données lidar brutes ont été utilisées dans ce projet. Plusieurs acquisitions ont été nécessaires pour couvrir l'ensemble du territoire visé. Un total de 46 710 tuiles lidar ont été récupérées, totalisant 3.29 To. Les acquisitions les plus récentes ont été priorisées. Celles, plus anciennes, datent de 2010 tandis que les plus récentes datent de 2020 (Figure 2). Il faut également préciser que les données lidar acquises en 2015 sur l'île de Montréal (sans feuille, 15 points/m<sup>2</sup>) ont été utilisées pour l' entraînement initial des modèles.

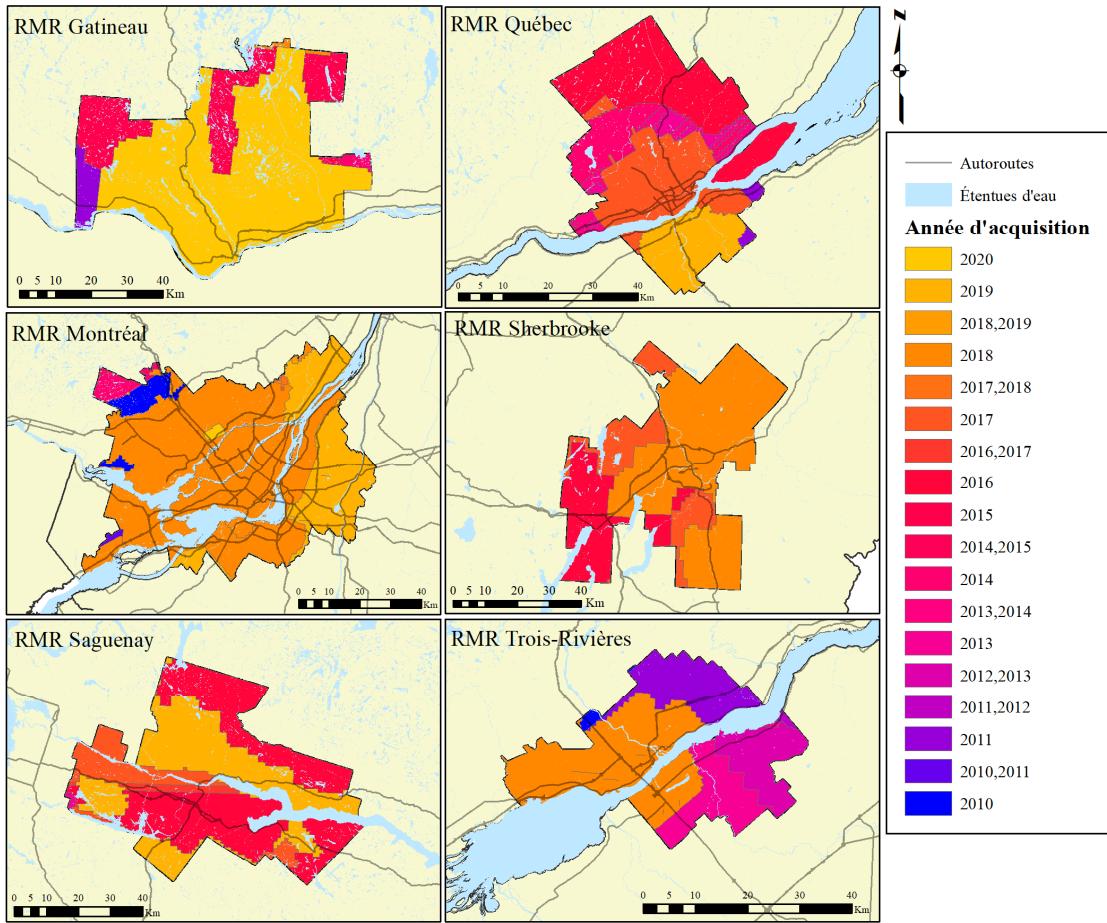


Figure 2. Année d'acquisition des données lidar utilisées.

Les données lidar ont également été acquises à différentes périodes de l'année. Celles acquises lorsque les feuilles étaient présentes dans les arbres ont été priorisées lorsque disponibles (Figure 3).

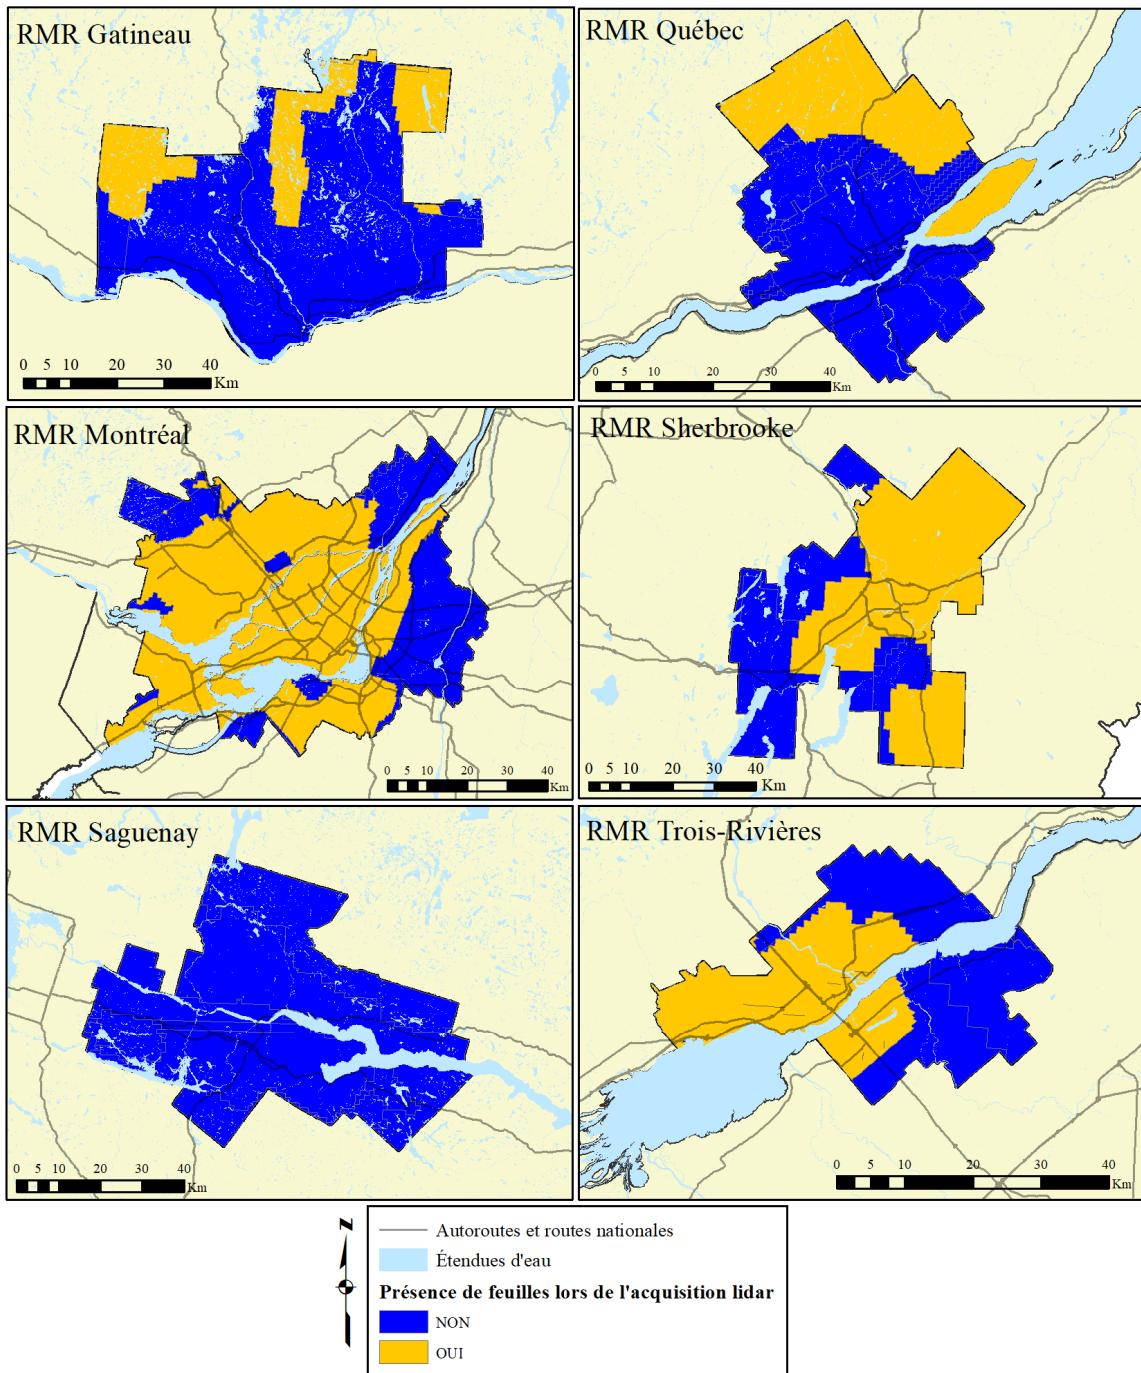


Figure 3. Présence de feuilles dans les arbres dans les acquisitions lidar utilisées.

Les nuages de points lidar utilisés présentent différentes densités moyennes de points. Parmi ces acquisitions, la plus faible densité moyenne est de 1 point/m<sup>2</sup> tandis que la plus forte densité moyenne est de 25 points/m<sup>2</sup> (Figure 4).

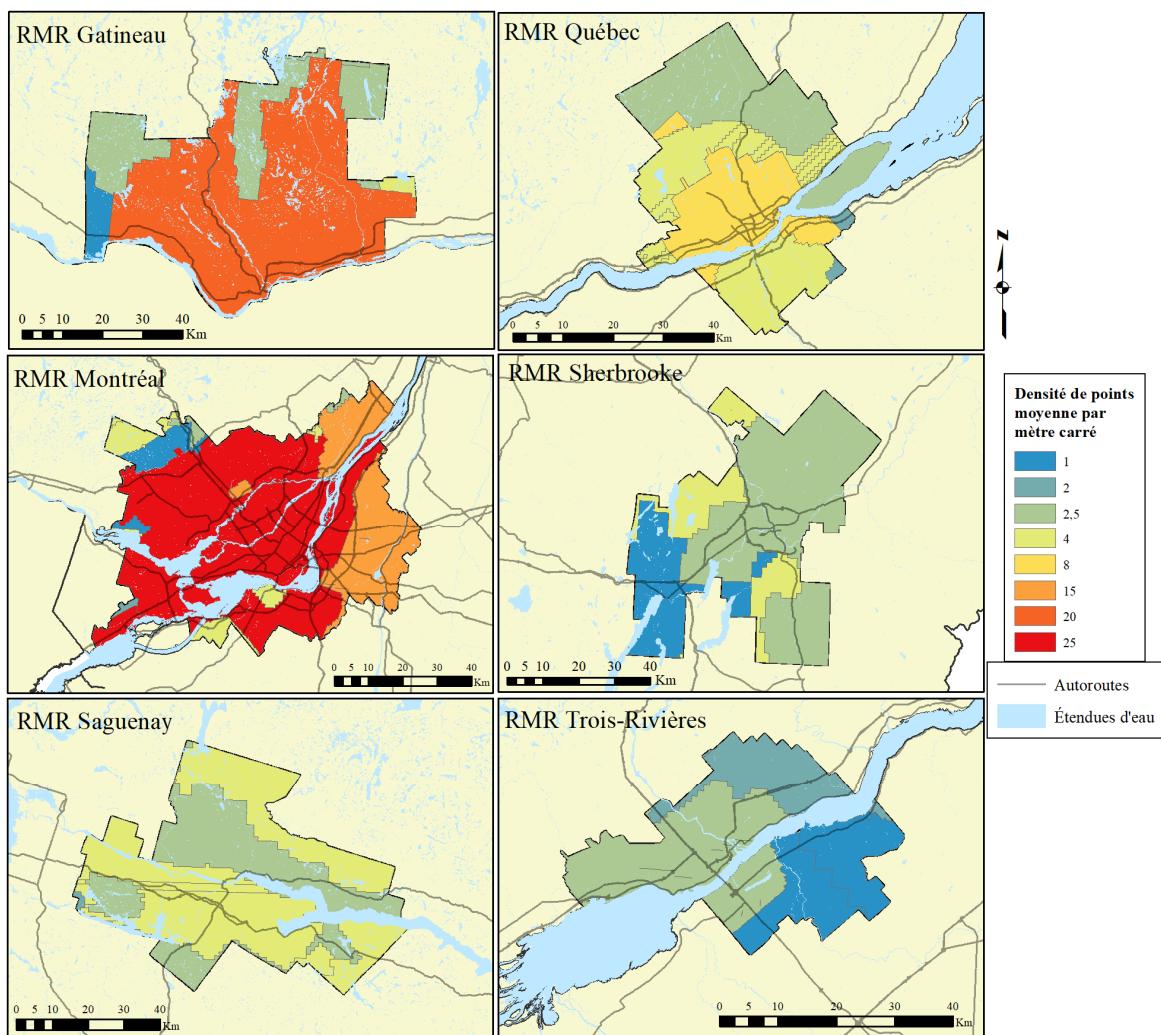


Figure 4. Densité moyenne de points des données lidar utilisées.

Dans les RMR de Montréal, Trois-Rivières et Québec, certaines zones ne présentaient pas de données lidar brutes disponibles lors de la réalisation du projet (Figure 5). Pour contourner cette absence de donnée, les modèles numériques de hauteurs (MNH) produits par le gouvernement du Québec ont été téléchargés pour développer un modèle spécifique à ces zones.

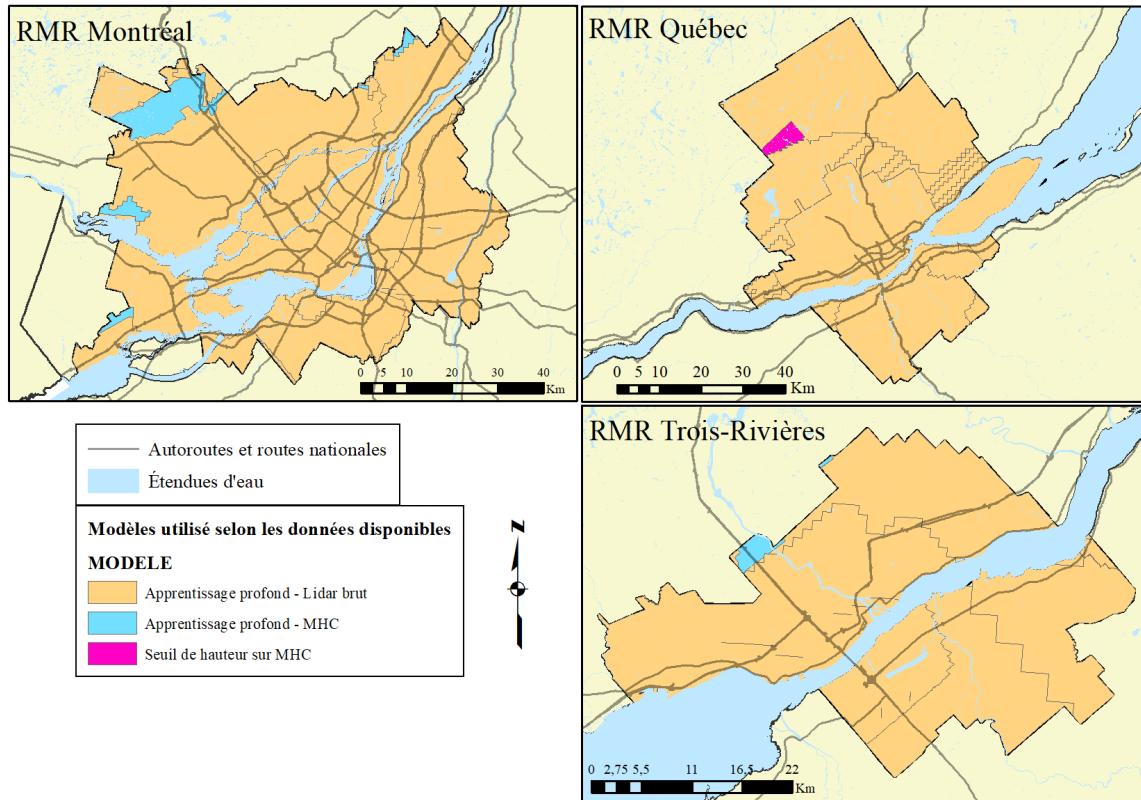


Figure 5. Zones ne contenant pas de données lidar brutes disponibles lors de la réalisation du projet et type de modèle appliquée.

### 3.2. Données de canopée de référence

La cartographie de la canopée de la ville de Montréal, réalisée avec des données lidar et des images aériennes acquises en 2015 (Ville de Montréal, 2022) a été utilisée comme canopée de référence pour l'entraînement du principal modèle prédictif adapté aux données lidar brutes (Figure 6). Cette cartographie a été conçue en utilisant de l'imagerie pour segmenter des zones de végétation, un lien a été fait avec le lidar 2015 disponible dans la ville de Montréal pour conserver uniquement la végétation d'une hauteur minimale de trois mètres.



*Figure 6. Extrait de la canopée de Montréal utilisé comme base de l'entraînement des modèles développés dans ce projet.*

#### 4. Méthodologie

La réalisation de ce projet a nécessité la mise en place d'une méthodologie de production de variables lidar à partir du nuage de points bruts. Ces données, combinées avec les cartographies de canopée à disposition, ont été impliquées dans un processus d'entraînement et de validation de plusieurs modèles d'apprentissage profond ayant conduit à la production finale de la canopée des six RMR du Québec. Ce processus a combiné plusieurs entraînements non supervisés, supervisés, des étapes de correction de données d'entraînement et des corrections manuelles des données produites. La Figure 7 synthétise les étapes réalisées dans le cadre de ce projet.

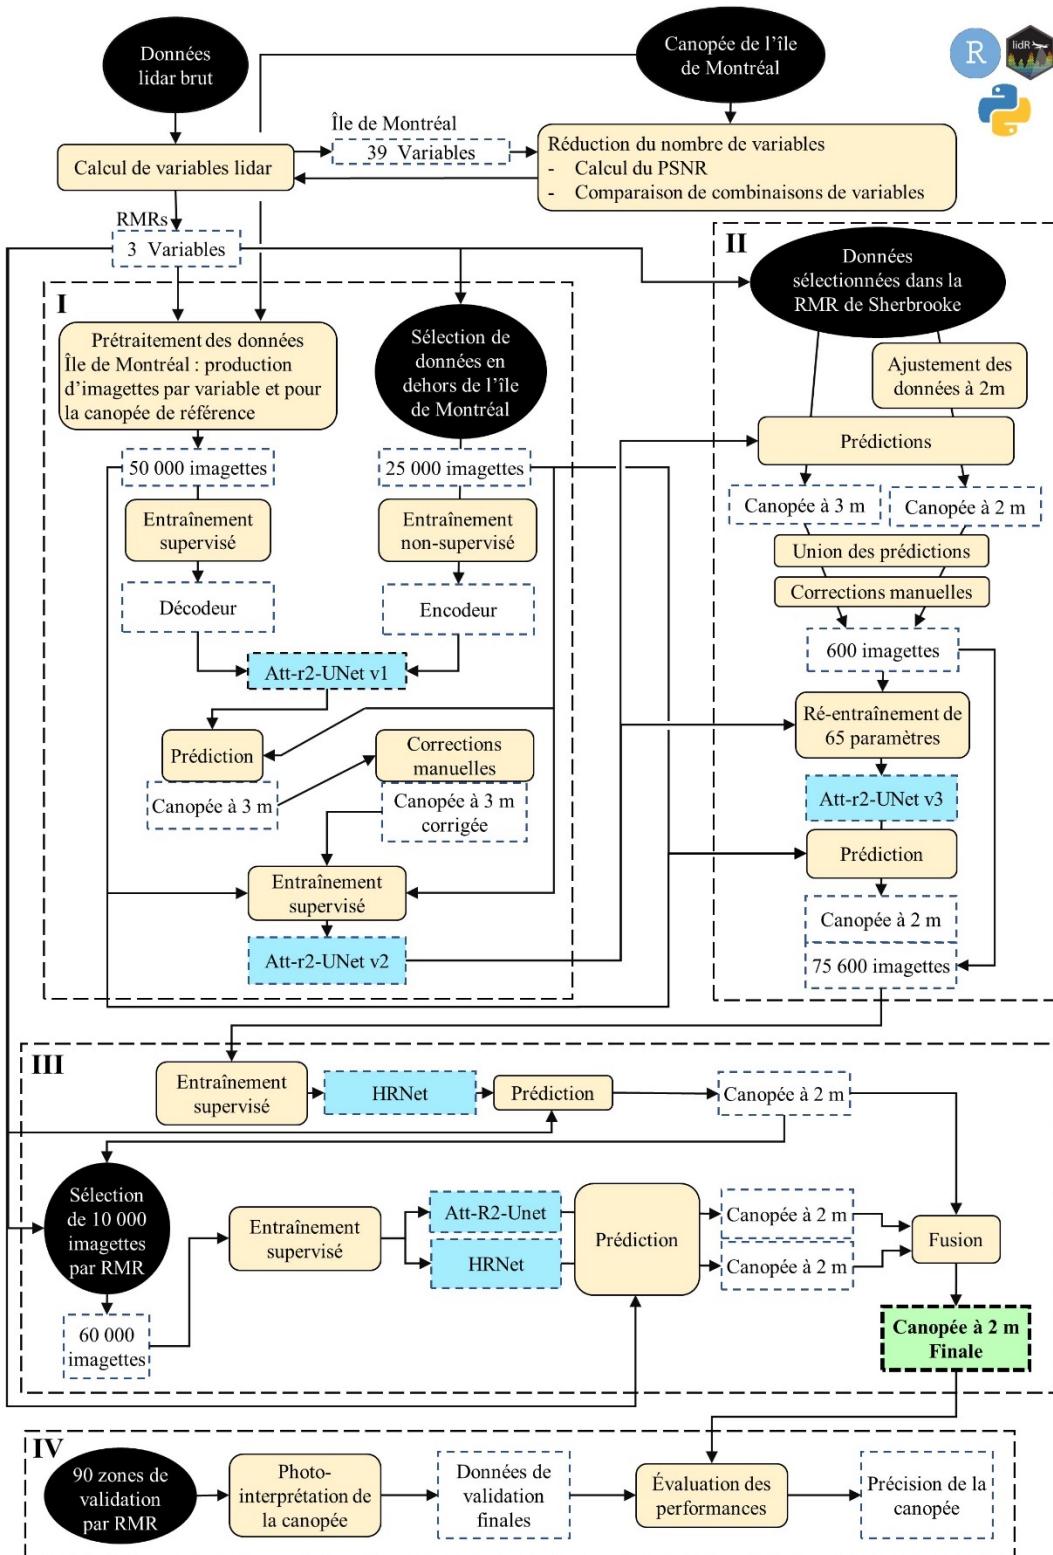


Figure 7. Schéma méthodologique des quatre grandes étapes réalisées pour produire la cartographie de la canopée des régions métropolitaines de recensement (RMR) du Québec. PSNR : proportion de signal sur bruit.

#### 4.1. Calculs de variables lidar

Les nuages de points lidar ont été utilisés pour calculer plusieurs variables décrivant leur structure verticale, à une résolution de 1 m<sup>2</sup>. La production de ces variables a été réalisée dans le logiciel R (R Development Core Team et Computing, 2010) et le package lidR version 3.2.3 (Roussel *et al.*, 2020). La majorité des données a été reçue avec une classification, celles n'en possédant pas ont été réparties afin d'identifier les points correspondant au sol. Les points répertoriés comme bruit ont été exclus du processus de calcul de variables. Les nuages de points ont été normalisés afin d'obtenir la hauteur des éléments présents sur le terrain. À partir des nuages de points normalisés, un total de 39 variables a été calculé par pixel sur les données lidar acquises en 2015 sur l'île de Montréal (Tableau 2). Suivant le processus de sélection de variables, uniquement celles sélectionnées ont été calculées sur la totalité des RMR. Un remplissage des pixels ne contenant pas d'information a été réalisé pour chaque variable en utilisant une fenêtre mobile 3x3. Aucun autre post-traitement n'a été effectué sur les variables.

Tableau 2. Liste et description des variables calculées par pixel à partir des nuages de points bruts.

Variable	Description
Modèle numérique de hauteur	Hauteur maximale du pixel.
Percentiles de hauteur 5 à 95 %	Hauteur en dessous de laquelle on retrouve X % des retours lidar.
Kurtosis	Description de l'aplatissement de la distribution verticale des retours lidar.
Skewness	Description de l'asymétrie de la distribution verticale des retours lidar.
Écart-type	Mesure de dispersion des valeurs de hauteur.
Coefficient de variation	Mesure de dispersion relative des valeurs de hauteur.
Hauteur moyenne	Moyenne de la hauteur des retours lidar.
Entropie de la hauteur	Mesure de la complexité verticale de la distribution verticale des retours lidar.
<i>Canopy relief ratio</i>	Ratio entre hauteurs moyennes, minimales et maximales.
Pourcentage de points au-dessus de 3 m de hauteur	-
Pourcentage de points au-dessus de la hauteur moyenne	-
Hauteurs cumulatives de 5 à 95 %	-
Distance interquartile	Mesure de dispersion des valeurs de hauteur des retours lidar.

#### 4.2. Réduction du nombre de variables lidar

Cette étape est cruciale pour le développement de la méthode, car elle permet d'abord de réduire de façon considérable le temps nécessaire pour le calcul des métriques lidar sur l'ensemble du territoire, mais accélère également l'optimisation des algorithmes de segmentation. Un choix judicieux des métriques est important pour fournir à l'algorithme des informations riches et complémentaires aidant la segmentation de la canopée.

#### 4.2.1. Choix de l'algorithme

L'algorithme utilisé pour la sélection de métriques lidar est basé sur une technique de réduction de bandes hyperspectrales. En effet, Ahmad, Mehmood Khan et Protasov (2017) ont montré qu'il est possible de faire la réduction de bandes d'imagerie hyperspectrale à l'aide d'un auto-encodeur entraîné à débruiter les images. Les résultats indiquent d'autant plus que des classificateurs (p. ex. Support Vector Machine, Random Forest, perceptron, Convolution Neural Network) fournissent de meilleures performances avec la réduction de bandes par auto-encodeurs que par les méthodes conventionnelles telles que l'ACP (Analyse en composantes principales) ou la LEM (*Laplacian Eigenmaps*). Cette technique permet donc de réduire le nombre de bandes ou de variables grâce à l'information spectrale et spatiale et est intéressante pour une tâche de segmentation. La Figure 8 schématise le processus utilisé.

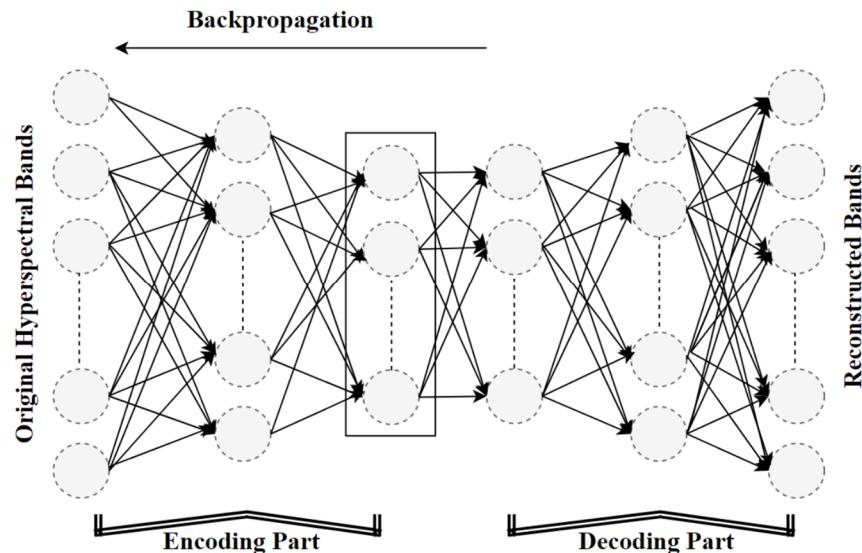


Figure 8. Schéma d'un auto-encodeur développé pour la sélection de bandes hyperspectrales (extrait de Ahmad et al. (2017), p. 4).

#### 4.2.2. Sélection de variables

Les variables initiales produites pour la sélection, détaillées dans les Tableau 1 et Tableau 3, ont été produites sur l'ensemble de l'île de Montréal. De façon non supervisée, l'algorithme a été entraîné à retirer du bruit ajouté aléatoirement. L'algorithme a ensuite été appliqué pour retirer le bruit d'une zone de validation. La proportion de signal sur bruit (PSNR) a été mesurée pour cette zone. Afin de réduire autant que possible le temps de calcul des variables pour tout le territoire, tout en permettant à l'algorithme d'avoir assez d'informations pour la segmentation de la canopée, trois variables lidar fournissant le meilleur PSNR, tout en étant les moins corrélées possibles, ont été sélectionnées.

*Tableau 3. Résultats du PSNR (proportion de signal sur bruit) pour la reconstruction des zones bruitées en validation lors de la sélection des variables lidar. Les lignes vertes indiquent les variables sélectionnées et les lignes jaunes indiquent les variables testées en segmentation, mais rejetées lors des tests préliminaires.*

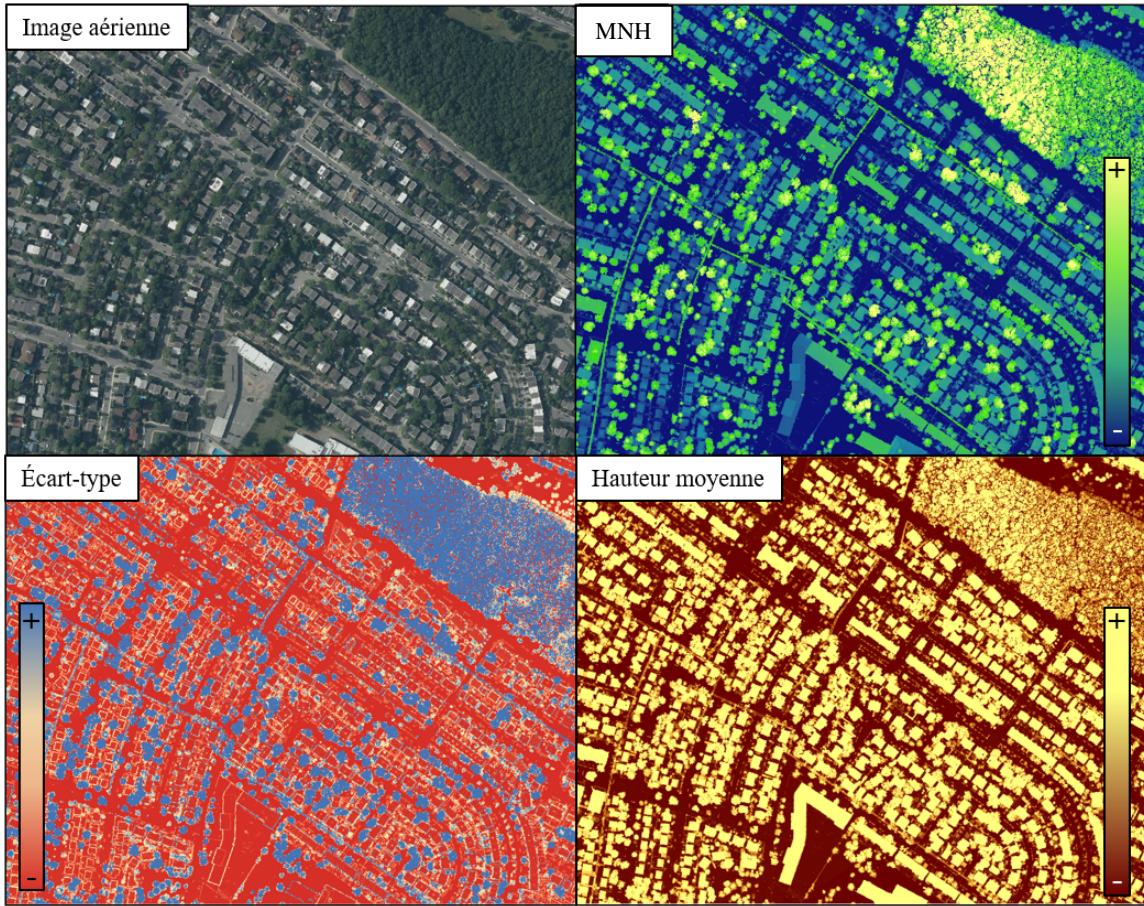
Variables	PSNR
Hauteurs cumulatives 5 %	40,55
Hauteurs cumulatives 15 %	39,52
Hauteurs cumulatives 25 %	38,28
Écart-type	37,87
Hauteur moyenne	37,22
Hauteurs cumulatives 35 %	36,91
Modèle numérique de hauteur	35,13
Hauteurs cumulatives 45 %	34,92
<i>Skewness</i>	32,39
Hauteurs cumulatives 85 %	31,14
Hauteurs cumulatives 95 %	30,65
<i>Kurtosis</i>	26,31
Coefficient de variation	26,31
Pourcentage de points au-dessus de 3m de hauteur	25,11
<i>Canopy relief ratio</i>	22,95
Entropie de la hauteur	22,01
Pourcentage de points au-dessus de la hauteur moyenne	21,63

À noter que les hauteurs cumulatives sont très corrélées entre-elles, ce qui explique qu'elles se retrouvent dans les variables étant les mieux reconstruites. De plus, bien que la variable hauteurs cumulatives 95 % soit très corrélée au MNH, ce dernier a un meilleur PSNR, ce qui a motivé sa sélection pour des tests de segmentation préliminaires.

Afin de déterminer la meilleure combinaison de variables, un entraînement de segmentation a été fait sur le jeu de données de Montréal, comparant les trois combinaisons possibles ;

1. MNH, hauteur moyenne et écart-type,
2. Hauteurs cumulatives 5 %, hauteur moyenne et écart-type,
3. Hauteurs cumulatives 95 %, hauteur moyenne et écart-type.

Les trois variables sélectionnées ayant permis d'atteindre les meilleures performances sont le MNH, la moyenne de la hauteur des points lidar et l'écart-type de la hauteur des points (Figure 9).



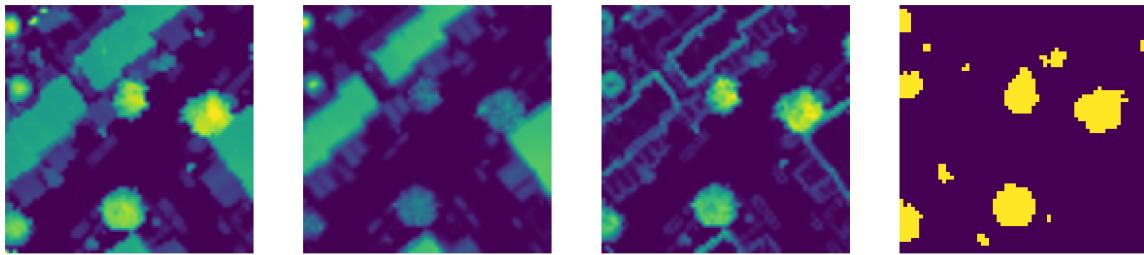
*Figure 9. Illustration des variables sélectionnées pour prédire la canopée des régions métropolitaines de recensement. MNH : modèle numérique de hauteur.*

### 4.3. Préparation des données

#### 4.3.1. Prétraitement des données

Les images utilisées par les algorithmes d'apprentissage profond ont été prétraitées pour améliorer les performances de détection (Figure 10). Ce prétraitement consiste en trois étapes :

1. Découpage des variables lidar et données de canopée de référence en imagettes carrées de 64 par 64 pixels (1 pixel = 1 mètre). Pour augmenter le nombre total d'imagettes créées, ce découpage est fait avec une superposition de 50 % ;
2. Chaque imagette est ensuite rééchantillonnée à une taille de 128 par 128 pixels de façon bilinéaire. Il s'agit d'une stratégie souvent utilisée en apprentissage profond pour aider à la détection de petits objets ou d'objets minces en augmentant le nombre de pixels qui les composent ;
3. Chaque imagette est finalement standardisée avec la moyenne et l'écart-type des variables, calculées sur l'ensemble du territoire d'étude.



*Figure 10. Exemple d'imagette créée pour le jeu d'entraînement initial. De gauche à droite modèle numérique de hauteur, hauteur moyenne, écart-type et annotation manuelle de la canopée provenant de la donnée de référence.*

À noter que cette préparation implique que le même prétraitement doit être appliqué lors de la prédiction puisque l'algorithme a été entraîné avec ce type de données.

#### 4.3.2. Création des jeux de données initiaux

Afin de séparer le jeu de données pour l'entraînement, les tests et la validation, des zones ont été choisies aléatoirement sur l'île de Montréal. Ces zones, qui totalisent 34 km<sup>2</sup> (Figure 11), ont été retirées du jeu de données d'entraînement puis séparées en jeux de données de tests et de validation. Au total, les jeux de données d'entraînement, de tests et de validation comptent respectivement 45 000, 2 500 et 2 500 imagettes.

## Emplacement des données d'entraînement et de validation sur l'île de Montréal

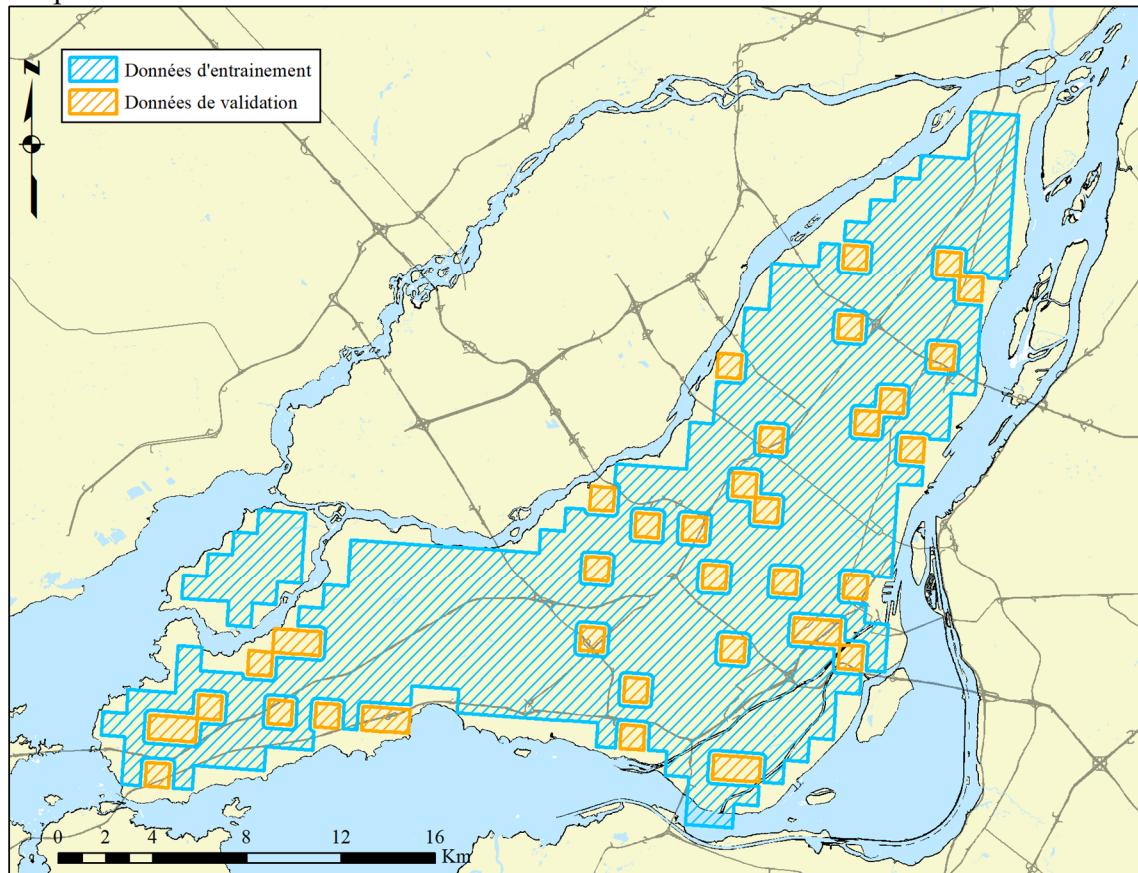


Figure 11. Répartition des zones d'entraînement (entraînement + test) et de validation pour le jeu d'entraînement de la segmentation de la canopée (trois mètres et plus) sur l'île de Montréal.

### 4.4. Bonification du jeu de données de segmentation de la canopée (trois mètres et plus)

Les algorithmes prédictifs sont connus pour être moins performants lorsqu'ils sont appliqués sur des données très différentes de celles avec lesquelles ils ont été entraînés. Dans ce projet, puisque les données de canopée disponibles ne couvraient que l'île de Montréal avec des données lidar acquises lors de l'absence de feuilles, il était pressenti que l'algorithme performe moins bien en dehors de Montréal ou pour des zones où le lidar a été acquis lors de la présence de feuilles. Afin d'éviter cette baisse de performances, un plus grand jeu de données a été construit (Figure 7; I), prenant en compte diverses conditions d'acquisitions dans les données à prédire et des secteurs situés dans toutes les RMR.

#### 4.4.1. Théorie - Apprentissage non supervisé et par transfert

Un entraînement non supervisé est une façon de faire apprendre des caractéristiques d'intérêt à un algorithme sans avoir besoin d'annotations ou d'exemples. Il existe plusieurs techniques

d'entraînement non supervisé adaptées à différentes tâches d'apprentissage profond. Dans ce projet, l'entraînement non supervisé a été utilisé pour apprendre à un algorithme à encoder des données lidar pour faciliter la compréhension de la donnée et la distinction d'objets dans les images.

Parmi les raisons pouvant introduire des erreurs, le surapprentissage et le manque de généralisation sont des problèmes communs. Pour éviter ces problèmes, l'une des solutions consiste à diminuer le nombre de paramètres nécessaires à l'entraînement d'un algorithme. C'est là qu'intervient l'apprentissage par transfert : il n'est pas nécessaire d'entraîner un algorithme au complet s'il est déjà capable de faire certaines tâches. Une tâche connexe peut alors être apprise avec très peu d'entraînement. Quelque chose de complexe comme de la classification d'images, nécessitant l'entraînement d'algorithmes à plusieurs millions de paramètres, peut alors se faire en entraînant un algorithme à quelques centaines de paramètres sans perte de performance.

#### 4.4.2. Choix des zones pour élaboration du jeu de données

Un jeu de données constitué des différentes conditions (plusieurs années d'acquisitions, sans et avec feuilles, différentes régions) a été créé en découplant dans certaines RMR des tuiles de 2 km par 2 km (Figure 12). Ces tuiles ont ensuite été redécoupées en imagettes de 64 par 64 pixels pouvant être fournies à l'algorithme en entrée.

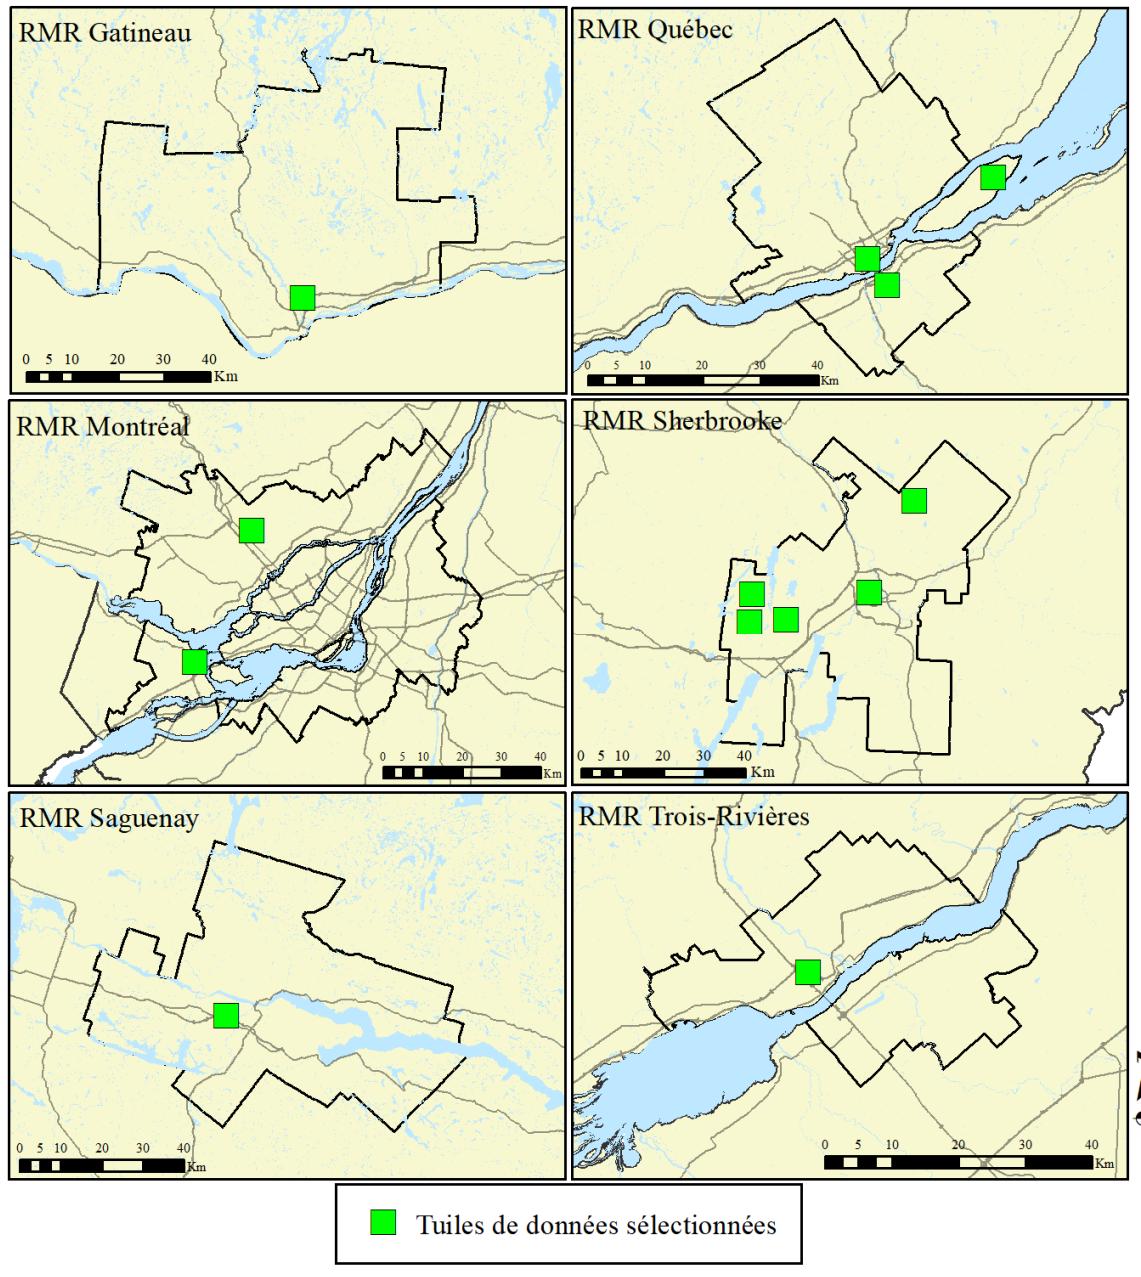


Figure 12. Emplacement des données d'entraînement ajoutées en dehors de l'île de Montréal.

#### 4.4.3. Entraînement non supervisé et par transfert

La technique d'apprentissage non supervisé qui a été utilisée est un protocole développé par l'équipe de « Facebook AI Research » (Bardes *et al.*, 2021). Cette technique permet de tirer avantage du fait qu'un objet, même s'il est modifié, reste le même objet. Ainsi, même si la couleur change, l'image est bruitée ou subit une rotation, la nature de l'objet ne change pas. La base (encodeur) d'un « *attention residual recurrent unet* » a donc été entraînée à produire le

même encodage pour une image et sa copie modifiée (Figure 7; I). La Figure 13 schématise les étapes de l’entraînement non supervisé.

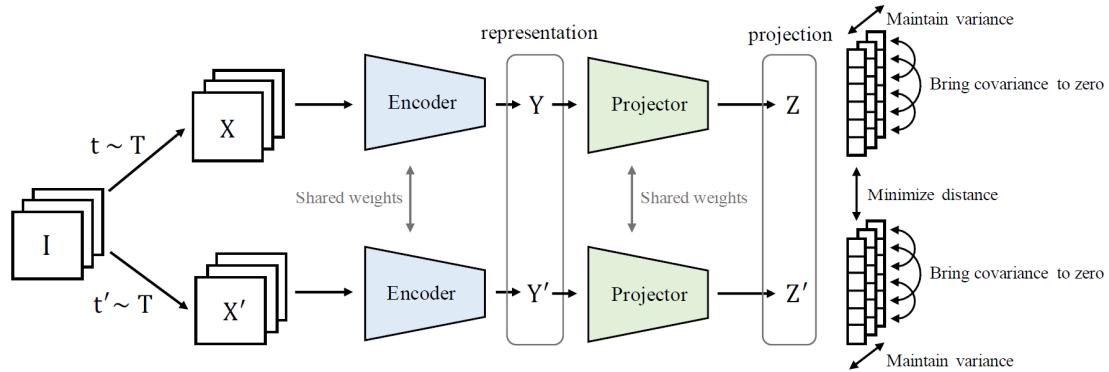


Figure 13. Schéma de l’algorithme non supervisé VICReg utilisé pour l’entraînement d’un encodeur (extrait de Bardes, Ponce, & LeCun, 2022, p. 2).

L’entraînement a été considéré comme terminé lorsque la variance, entre les encodages de l’image et de sa copie, a atteint un plateau et donc que l’algorithme a reproduit à son mieux le même encodage pour les deux images.

Par la suite, les paramètres de l’encodeur du « *attention residual recurrent unet* » ont été fixés (ils n’ont pas été inclus dans les entraînements suivants) et l’encodeur a été relié au décodeur pouvant faire la segmentation comme à la Figure 14. À cette étape, plus de 75 % des paramètres de l’algorithme de segmentation étaient fixes et seulement 1,5 million de ceux-ci restaient à être entraînés. Le jeu de données de segmentation de la canopée de la ville de Montréal a ensuite été utilisé pour entraîner de façon supervisée le modèle complet et ainsi obtenir un premier modèle de segmentation automatique de la canopée (Figure 7; I).

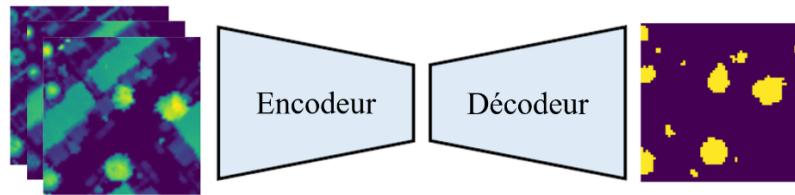


Figure 14. Apprentissage par transfert en récupérant l’encodeur préentraîné.

#### 4.4.4. Apprentissage actif

Bien que l’apprentissage non supervisé et l’apprentissage par transfert aient permis d’augmenter la généralisation et de prédire sur un plus grand éventail de conditions, certaines erreurs étaient attendues, principalement des erreurs de commission dues à l’arrivée de nouveaux éléments observables sur les différentes zones (p. ex. bateaux, chutes, pylônes électriques).

Afin d’augmenter la robustesse et la performance de l’algorithme face à ces nouvelles conditions, une solution simple est d’avoir recours à l’apprentissage actif (Settles, 2009). Des

prédictions de canopée ont été réalisées dans les zones découpées (Figure 12) par l'algorithme puis des correctifs manuels sont apportés pour augmenter la précision de la segmentation à plus de 90 %. Le Tableau 4. Résultats de la segmentation de la canopée sur les tuiles tests montre l'évaluation des performances de l'algorithme ainsi que les tuiles ayant nécessité des corrections manuelles.

*Tableau 4. Résultats de la segmentation de la canopée sur les tuiles tests. En jaune les tuiles qui ont eu des corrections manuelles et en rouge la tuile qui a été rejetée.*

Tuile	Évaluation de la performance [%]
Gatineau	< 70
Île d'Orléans	90
Québec	95
Lévis	90
Montréal (Ouest)	80
Lanaudière	80
Roussillon	95
Sherbrooke sans feuille	90
Sherbrooke avec feuilles	85
Estrie (milieu humide)	95
Saguenay	90
Trois-Rivières	80

En conclusion, la démarche de bonification du jeu de données a permis de prédire onze zones tests sur douze, où seules quatre ont nécessité des corrections manuelles et, ainsi, bonifier le jeu de données initial avec plus de 25 000 imagettes annotées hors Montréal dans diverses conditions. À noter qu'un nouvel algorithme a été entraîné avec ces nouvelles données et que celui-ci a réussi à atteindre de bonnes performances sur la tuile de Gatineau qui présentait la plus faible performance (Tableau 4. Résultats de la segmentation de la canopée sur les tuiles tests).

#### **4.5. Création d'un jeu de données de segmentation de la canopée (deux mètres et plus)**

À cette étape, les algorithmes de segmentation entraînés ne pouvaient identifier la canopée qu'à partir de trois mètres de hauteur et plus, puisque la donnée d'entraînement initiale de la canopée de Montréal a été produite avec ce seuil. Afin de parvenir à segmenter la canopée deux mètres et plus, certaines manipulations ont été effectuées pour créer une donnée de base utilisée pour entraîner un algorithme à avoir une bonne performance pour cette nouvelle segmentation (Figure 7; II).

##### **4.5.1. Altération des données pour prédire à deux mètres et plus**

La première étape a été la création d'une donnée de segmentation de la canopée avec un seuil de deux mètres de hauteur minimum. Ce paramètre a été ensuite utilisé en apprentissage par transfert pour corriger les prédictions du modèle original. La stratégie a donc été de fusionner deux prédictions d'une nouvelle zone test, sélectionnée dans la RMR de Sherbrooke :

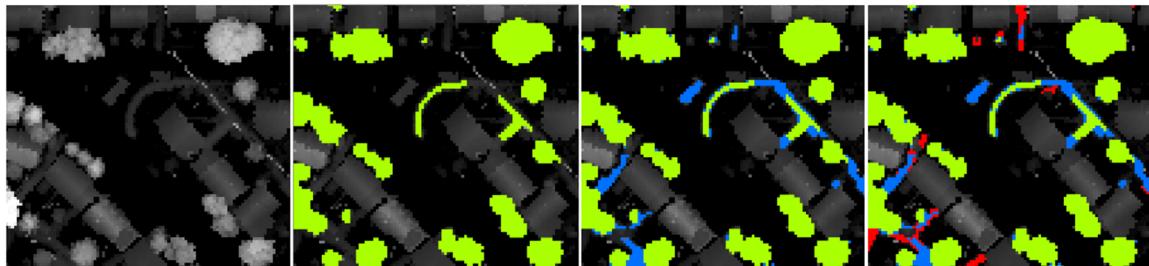
1. Prédiction originale segmentant la canopée de trois mètres et plus ;
2. Prédiction obtenue en « trompant » l'algorithme, c'est-à-dire en modifiant les données d'entrées pour lui faire croire que les arbres sont tous d'un mètre plus grands qu'ils le sont en réalité grâce aux équations suivantes (à noter qu'aucune modification n'est apportée à l'écart-type) :

$$MNH \text{ où } [Moyenne \geq 2] \rightarrow MNH + 1$$

$$Moyenne \text{ où } [Moyenne \geq 2] \rightarrow Moyenne + 1$$

3. La prédiction finale retenue pour la tuile de Sherbrooke est l'union de tout ce qui a été identifié dans les deux prédictions.

Cette stratégie a permis d'identifier de nombreux petits arbres sous la barre des trois mètres, mais s'est avérée moins efficace pour la segmentation des haies, qui constituent un nouvel élément à prédire peu présent dans la canopée de trois mètres et plus. Des corrections manuelles ont donc été apportées à cette dernière prédiction pour créer une donnée de segmentation de la canopée à deux mètres et plus très précise (voir Figure 15. Exemple d'une zone prédite avec de gauche à droite : le modèle numérique de hauteur, la prédiction de trois mètres et plus (vert), la prédiction de deux mètres et plus (bleu) et les corrections manuelles apportées (rouge).).



*Figure 15. Exemple d'une zone prédite avec de gauche à droite : le modèle numérique de hauteur, la prédiction de trois mètres et plus (vert), la prédiction de deux mètres et plus (bleu) et les corrections manuelles apportées (rouge).*

#### 4.5.2. Apprentissage par transfert pour la prédiction automatique (deux mètres et plus)

Bien que la canopée de la tuile sélectionnée dans la RMR de Sherbrooke segmentée à deux mètres et plus ne fournisse pas assez de données pour entraîner un algorithme initialisé de zéro, il est possible de procéder à un apprentissage par transfert pour réentraîner quelques paramètres seulement du modèle précédent.

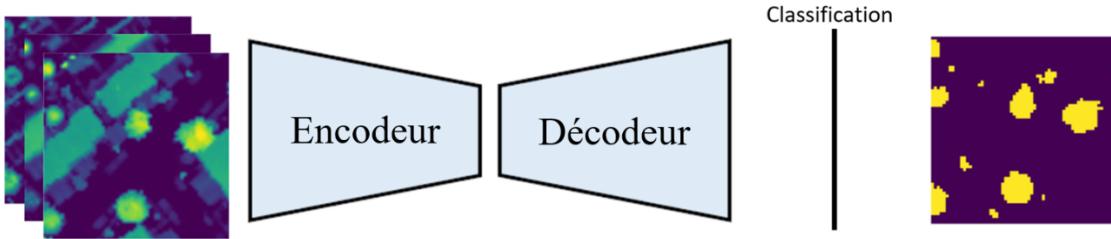


Figure 16. Schéma de l'entraînement par transfert de l'algorithme de segmentation de la canopée (deux mètres et plus).

Cette fois-ci, comme illustré à la Figure 16, uniquement la couche de classification est entraînée sur le jeu de données de Sherbrooke, c'est-à-dire 65 paramètres seulement. Le petit nombre de paramètres permet d'éviter des problèmes de surapprentissage étant donné la faible quantité de données. De plus, le fait d'entraîner uniquement la couche de classification permet de garder le modèle initial (encodeur et décodeur) intact et assure donc de garder une bonne généralisation et une robustesse envers les différentes conditions possibles malgré un entraînement très spécifique sur une zone de Sherbrooke. Une fois le modèle entraîné, les douze tuiles tests sont prédites par l'algorithme, qui sont ajoutées au jeu d'entraînement de segmentation de deux mètres et plus.

#### 4.5.1. Finition du jeu de données deux mètres et plus

À cette étape, deux jeux de données sont disponibles : un premier jeu de données de trois mètres et plus de l'île de Montréal comptant plus de 50 000 imagettes et un de deux mètres et plus de douze tuiles tests d'environ 25 000 imagettes. Ayant un large jeu d'entraînement pour les deux types de segmentation, un nouveau modèle a été choisi. Le HRNet (Wang *et al.*, 2020), ayant deux fois plus de paramètres que le modèle précédent, est parfois susceptible au surentraînement si le nombre de données n'est pas suffisant, mais fournit l'état de l'art pour plusieurs tâches de segmentation sur les grands jeux de données. De plus, il est modélisé pour garder l'intégrité de la résolution lors de la segmentation et tend à fournir une meilleure précision pour les structures et les plus petits objets.

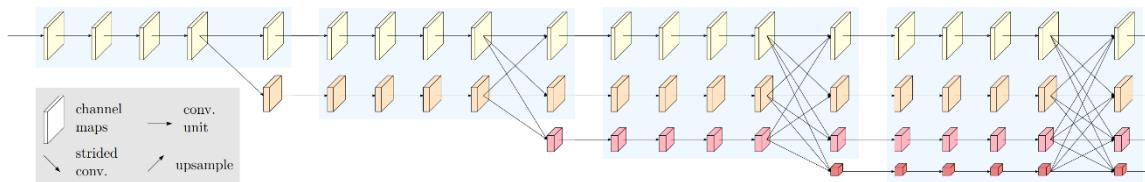


Figure 17. Schéma de la structure du HRNet (extrait de Wang *et al.* (2019), p. 3).

Le HRNet est donc d'abord entraîné sur le jeu de données de Montréal à trois mètres et plus, puis réentraîné sur le jeu de données de deux mètres et plus. Lors de cet apprentissage par transfert, le modèle a été réentraîné au complet sans fixer de paramètres et pour le même nombre d'étapes. Ce modèle est finalement utilisé pour prédire la canopée de l'île de Montréal à deux mètres et plus qui est ajouté au jeu d'entraînement deux mètres et plus.

## 4.6. Ensemble de modèles

Une des techniques les plus utilisées pour augmenter les performances des algorithmes d'apprentissage est l'utilisation d'un ensemble de modèles (Dong *et al.*, 2020). Le but est simple : profiter de l'avis de plusieurs « experts » pour prendre une décision. Différentes techniques peuvent être employées pour créer l'ensemble, reposant sur le même principe que : si ces « experts » ont une interprétation fondamentalement différente les uns des autres, il y a de fortes chances que les prédictions qu'ils fassent en commun s'avèrent être une bonne prédiction.

### 4.6.1. Apprentissage actif à large étendue

Dans le but de créer ce genre d'ensemble, un HRNet est réentraîné sur le jeu d'entraînement complet de deux mètres et plus et prédit la canopée sur l'ensemble des RMR (Figure 7; III). Une dernière phase d'apprentissage actif a ensuite lieu permettant de faire des corrections sur des éléments très peu présents, voire absents du jeu d'entraînement, mais pouvant se retrouver plusieurs fois dans les données à prédire et méritant une automatisation. Notamment, des corrections ont été faites dans les carrières et les raffineries, les pylônes électriques de Lévis, les camions sur les autoroutes et le pont Pierre Laporte. Celles-ci ont été ajoutées au jeu de données final et la prédiction des RMR a été enregistrée pour pouvoir être post-traitée lors de la compilation des prédictions de l'ensemble de modèles.

### 4.6.2. Choix des modèles pour l'ensemble

Comme mentionné plus haut, un ensemble de modèles sera profitable si ceux-ci sont différents les uns des autres. Afin de créer ces différences, deux modifications seront apportées au jeu de données :

1. Le champ de vision de l'algorithme est doublé en créant des imagettes de 128 par 128 pixels puis en les rééchantillonnant à 256 par 256 pixels (précédemment à 64 par 64 rééchantillonnée vers 128 par 128 pixels). Cette stratégie permet à l'algorithme de traiter une plus grande zone en même temps et donc de profiter d'une meilleure analyse contextuelle, tout en divisant par quatre la taille du jeu de données. Ayant un jeu de données segmenté avec précision de plusieurs dizaines de milliers d'imagettes, ce dernier inconvénient n'est pas problématique.
2. De nombreuses corrections ont été ajoutées dans le jeu de données grâce à la dernière étape, permettant d'augmenter la richesse de celui-ci. De plus, ayant maintenant les prédictions dans toutes les RMR, un nouveau balancement des données est effectué pour être réparti équitablement entre les différentes RMR et éviter les biais de performance pour une en particulier.

Ensuite, dans le but d'avoir au moins trois modèles dans l'ensemble, les deux architectures ayant fourni les meilleures performances jusqu'à présent sont choisies et entraînées sur le nouveau jeu de données, soit le *HRNet* et le *Attention residual recurrent Unet*. Le Tableau 5 suivant résume les paramètres d'entraînement des différents modèles constituant l'ensemble.

Tableau 5. Paramètres des trois modèles de l'ensemble.

	<b>Modèle 1</b>	<b>Modèle 2</b>	<b>Modèle 3</b>
<b>Architecture</b>	HRNet	HRNet	Att-R2-Unet
<b>Taille des intrants</b>	64x64	128x128	128x128
<b>Nombre de paramètres</b>	~42 millions	~42 millions	~24 millions
<b>Données d'entraînement</b>	Montréal et les douze tuiles tests 2 m+	5000 imagettes par RMR 2 m+	5000 imagettes par RMR 2 m+

#### 4.7. Prédictions sur l'ensemble du territoire et fusion

Une fois les modèles entraînés, ils peuvent être utilisés pour la segmentation automatique de la canopée sur l'ensemble du territoire (Figure 7; III). Cette détection se fait en deux principales étapes décrites dans les sous-sections suivantes.

##### 4.7.1. Extraction et préparation des imagettes pour la prédiction

Une fois que les trois variables (MNH, moyenne et écart-type) sont produites sur l'ensemble du territoire, des imagettes doivent être extraites pour produire la segmentation de la canopée. Pour ce faire, une fenêtre de 128 par 128 pixels (64 par 64 pour le premier modèle) balaie la grille à prédire pour en extraire les métriques qui seront ensuite prétraitées comme à la section « Prétraitement des données ». Afin de diminuer les effets de bordure et de maximiser les performances, une superposition de 50 % est utilisée entre les imagettes pendant le balayage.

##### 4.7.2. Segmentation automatique de la canopée

L'imagette préparée à l'étape précédente est prédite par les trois algorithmes. Les trois prédictions sont fusionnées de la façon suivante :

1. Les prédictions sont transformées sous forme binaire grâce à une valeur seuil de 0.5 ;
2. Les prédictions sont additionnées ;
3. Seuls les pixels ayant une valeur de deux ou plus (prédit par au moins deux des trois algorithmes) sont considérés comme la canopée et les autres sont retirés et mis à zéro.

Les imagettes ainsi traitées sont ensuite enregistrées sur la mosaïque de prédiction et le balayage est poursuivi jusqu'à ce que l'ensemble du territoire soit prédit.

#### 4.8. Zones avec données lidar manquantes

Afin de compléter les zones des RMR ne disposant pas de données lidar brutes, des alternatives ont été déployées. Concernant la RMR de Québec, la section ne disposant pas de données lidar brutes est située dans le nord de la RMR et est intégralement constituée de forêt (Figure 5). Pour cette zone, un seuil de hauteur de 2 m a été appliqué sur le MNH produit par le

gouvernement du Québec. Les pixels d'une hauteur supérieure à deux mètres ont été considérés comme étant de la canopée.

Pour les secteurs sans données lidar brutes de la RMR de Montréal et Trois-Rivières, l'occupation du territoire comprenait plusieurs milieux. Un seuil de hauteur aurait ici inclus des bâtiments ou autres structures de non-végétation. Un modèle d'apprentissage profond Att-R2-Unet a été entraîné avec les données d'entraînement précédemment utilisées et appliqué sur les M NH produits par le gouvernement du Québec, disponibles dans les zones sans données lidar brutes de la RMR de Montréal et Trois-Rivières.

#### 4.9. Validation des prédictions

Afin d'estimer les performances de la cartographie de canopée produite, plusieurs jeux de données de validation ont été créés par RMR (Figure 7; IV). Les performances ont été évaluées dans trois environnements distincts, soit les milieux urbains, ruraux et forestiers, identifiés grâce aux catégories d'occupation du territoire de la carte écoforestière du Québec méridional. La combinaison des trois milieux a été considérée pour évaluer la performance globale d'une RMR. Dans chaque milieu, la canopée a été photo-interprétée à partir du M NH et d'images aériennes dans 30 cellules de 50x50m. La canopée issue du modèle prédictif a été extraite pour chacune des cellules de validation. Des données de validation ont également été créées pour les zones utilisant uniquement la variable M NH.

La comparaison entre la canopée photo-interprétée et celle générée par le modèle a été réalisée, premièrement, par la compilation de matrices d'erreurs. La comparaison dans celles-ci a été exécutée à l'échelle du pixel. Les matrices d'erreurs contiennent le détail du nombre de pixels classifiés dans chaque classe (canopée ou non-canopée) et des statistiques générales : un score de précision globale et de coefficient de Kappa de Cohen (Cohen, 1960; Congalton, 1991). En supplément, les paramètres de sensibilité (taux de vrais positifs), de spécificité (taux de vrais négatifs), de précision, de probabilité de détection et de score-F1 (Sasaki, 2007; taux de recouvrement entre prédition et référence, pondéré par la surface combinée de ces dernières) ont été calculées.

Par la suite, un indice de canopée (ratio entre canopée et aire d'intérêt) a été calculé par cellule avec la canopée photo-interprétée et celle générée par le modèle. La relation entre l'indice de canopée de référence et prédit a permis d'établir un score de corrélation  $R^2$ . L'ensemble des cellules a été regroupé pour effectuer une comparaison de l'indice de canopée entre les prédictions issues de données lidar acquises lors de la présence et absence de feuilles dans les arbres.

## 5. Performances des modèles

### 5.1. Matrices d'erreurs

Pour chaque RMR, la comparaison effectuée entre la canopée photo-interprétée et la canopée prédictée par l'algorithme d'apprentissage profond a permis de quantifier les performances. Globalement, les performances de classification peuvent être considérées comme excellentes, traduites par des valeurs de précision globale allant de 0,9559 dans la RMR de Gatineau (Figure 18) à 0,9712 dans la RMR de Saguenay (Figure 22), ainsi que des valeurs de coefficient de kappa allant de 0,8996 dans la RMR de Gatineau (Figure 18) à 0,9393 dans la RMR de Saguenay (Figure 22).

De façon globale, le modèle montre un comportement similaire dans toutes les RMR avec un plus grand nombre d'erreurs de commission [sensibilité : 0,9651 – 0,9839] que d'omission [spécificité : 0,9341 – 0,9722], excepté dans la RMR de Trois-Rivières (Figure 23).

Concernant les milieux forestiers spécifiquement, les performances sont à la hauteur des performances globales. Les erreurs relevées sont balancées entre commission et omission, mais présentent une tendance à l'omission dans les RMR de Gatineau [commission = 840; omission = 2370] (Figure 18), Québec [commission = 1201; omission = 1709] (Figure 19), Sherbrooke [commission = 1488; omission = 2834] (Figure 21) et de manière plus prononcée dans la RMR de Trois-Rivières [commission = 983; omission = 3689] (Figure 23).

En milieu rural les performances observées sont similaires aux performances globales pour la RMR de Montréal (Figure 20). Dans les autres RMR, la précision globale est plus élevée avec des valeurs allant de 0,9687 pour la RMR de Gatineau (Figure 18) à 0,9723 pour la RMR de Québec (Figure 19). Cependant les valeurs de coefficient de Kappa sont plus faibles que dans les performances globales avec des valeurs allant de 0,8028 dans la RMR de Gatineau (Figure 18) à 0,9094 dans la RMR de Québec (Figure 19).

Finalement, dans le milieu urbain qui représentait le milieu le plus complexe pour effectuer les prédictions de canopée, les performances observées restent élevées, mais présentent plus de variabilité entre les RMR. Les valeurs de précision globale observées s'étendent de 0,9420 pour la RMR de Gatineau (Figure 18) à 0,9729 pour la RMR de Trois-Rivières (Figure 23) et des valeurs de coefficient de Kappa allant de 0,8420 pour la RMR de Gatineau (Figure 18) à 0,9204 dans la RMR de Sherbrooke (Figure 21). Tout comme les performances globales, le milieu urbain présente une proportion plus importante d'erreurs de commission que d'omission.

Concernant les performances du modèle utilisant uniquement le MNH comme variable prédictive, les performances globales sont comparables aux modèles utilisant trois variables. De façon globale, la précision globale observée est de 0,9737 et le coefficient de Kappa est de 0,9446 (Figure 24). Les erreurs effectuées sont balancées entre commission et omission, ce qui explique en partie la valeur de coefficient de Kappa élevée, cependant le nombre total de ces erreurs est plus grand qu'avec le modèle utilisant trois variables. Les performances les plus

faibles sont observées dans le milieu urbain (précision globale : 0,9542; coefficient de Kappa : 0,8546; Figure 24).

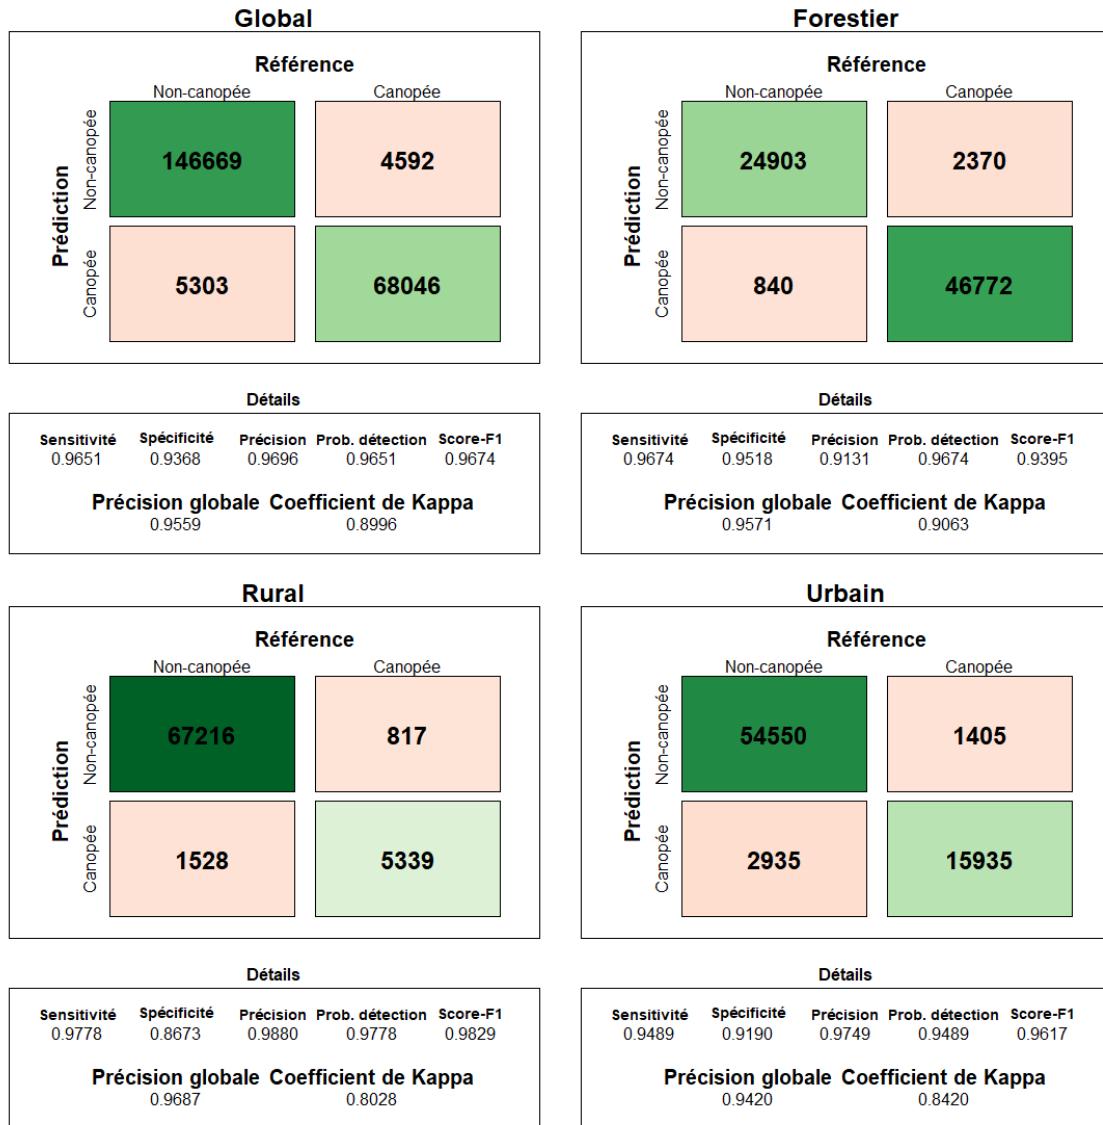


Figure 18. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Gatineau.

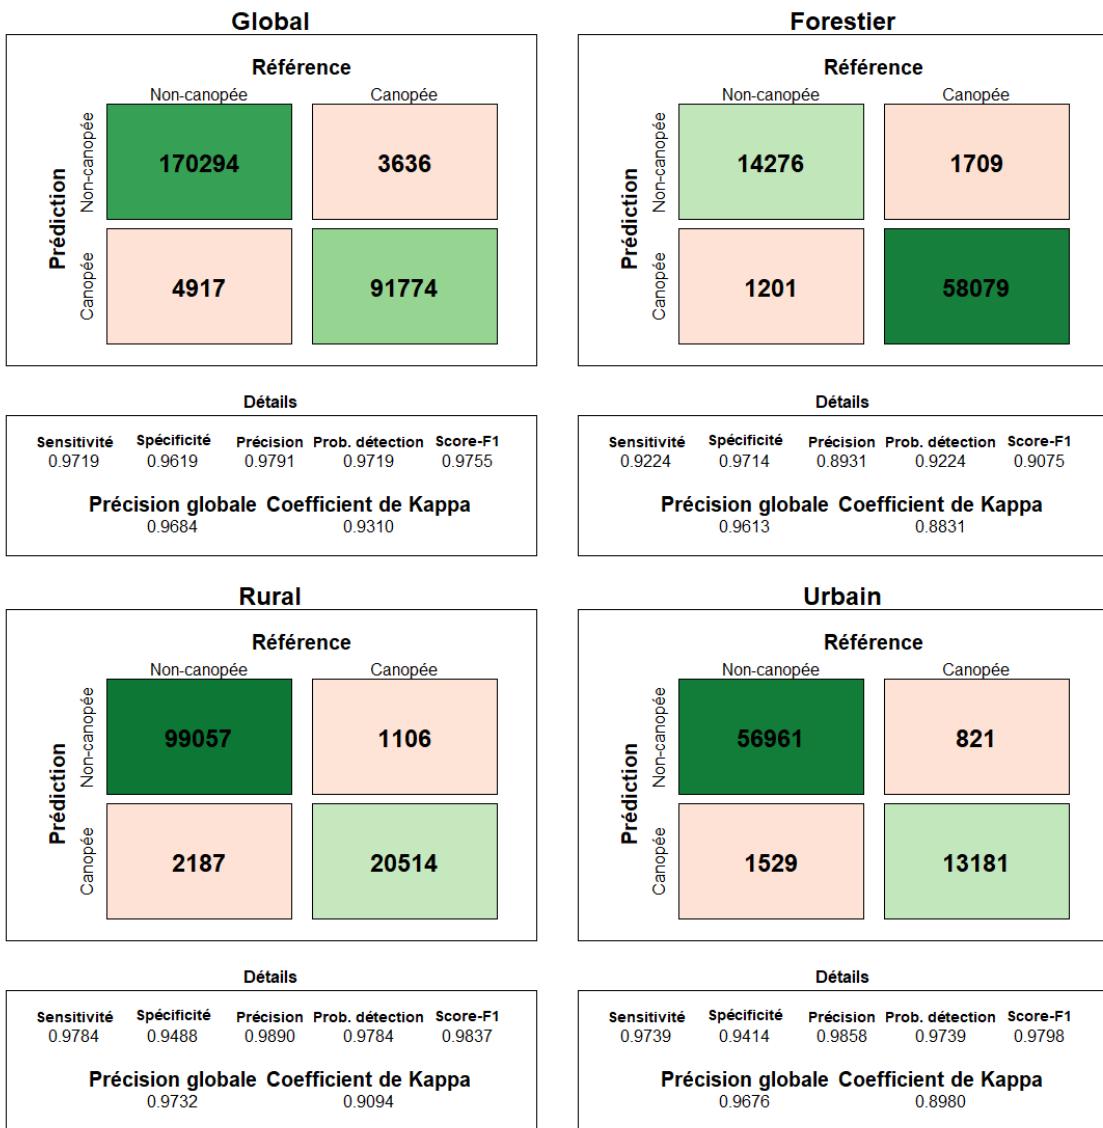


Figure 19. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Québec.

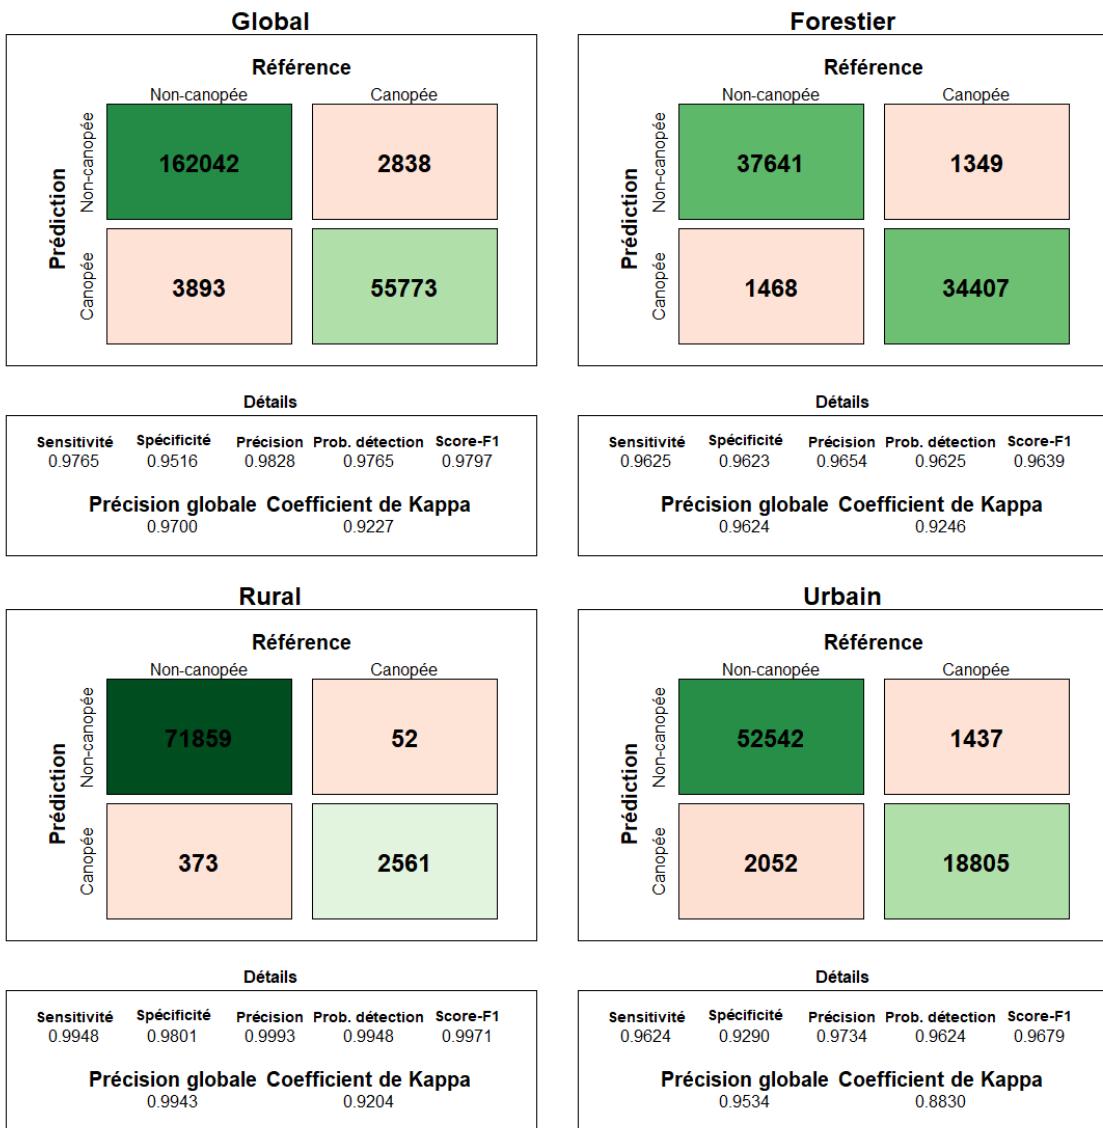


Figure 20. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Montréal.

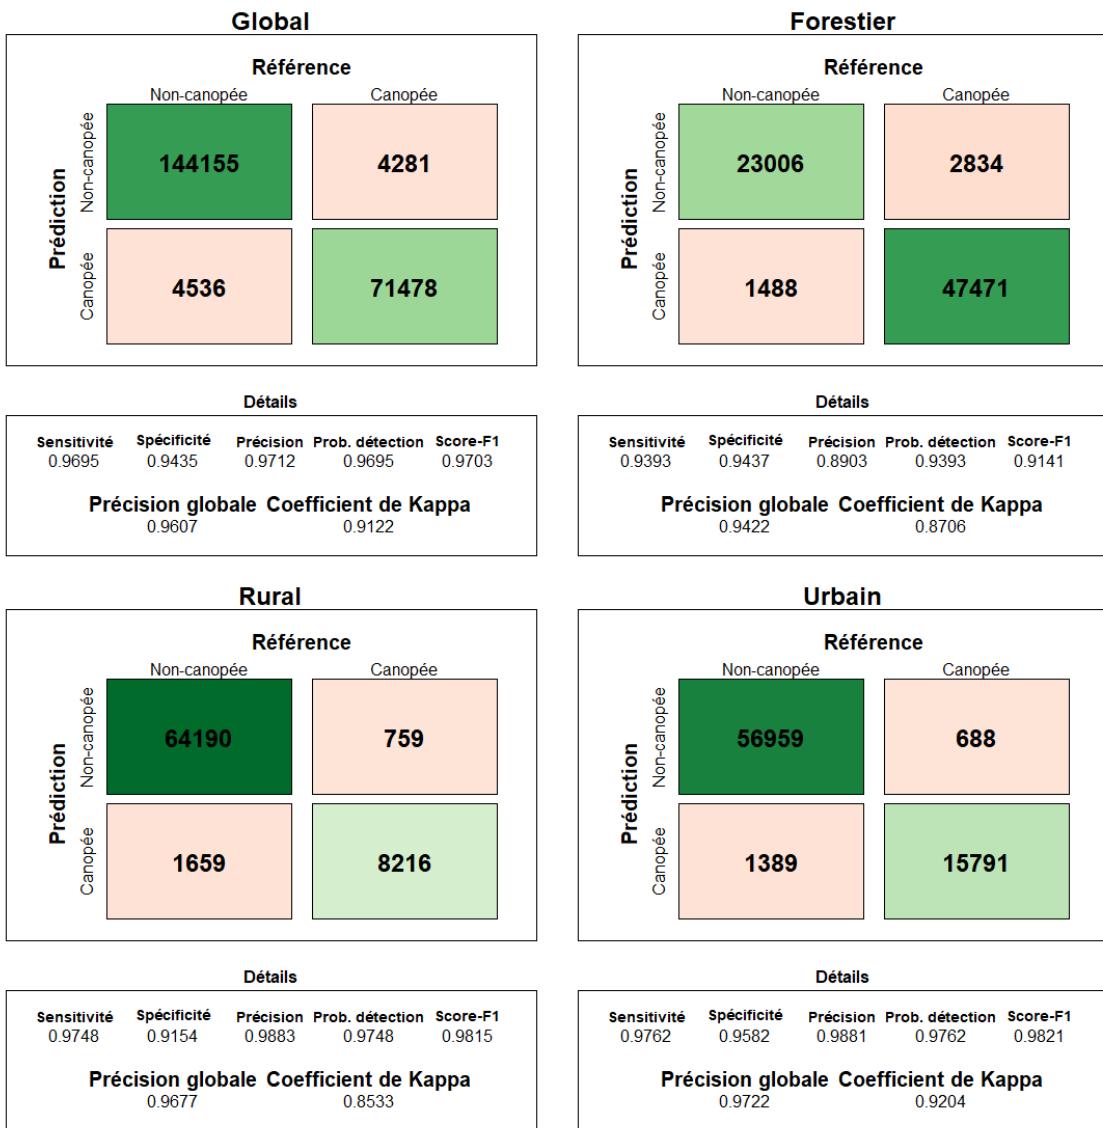


Figure 21. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Sherbrooke.

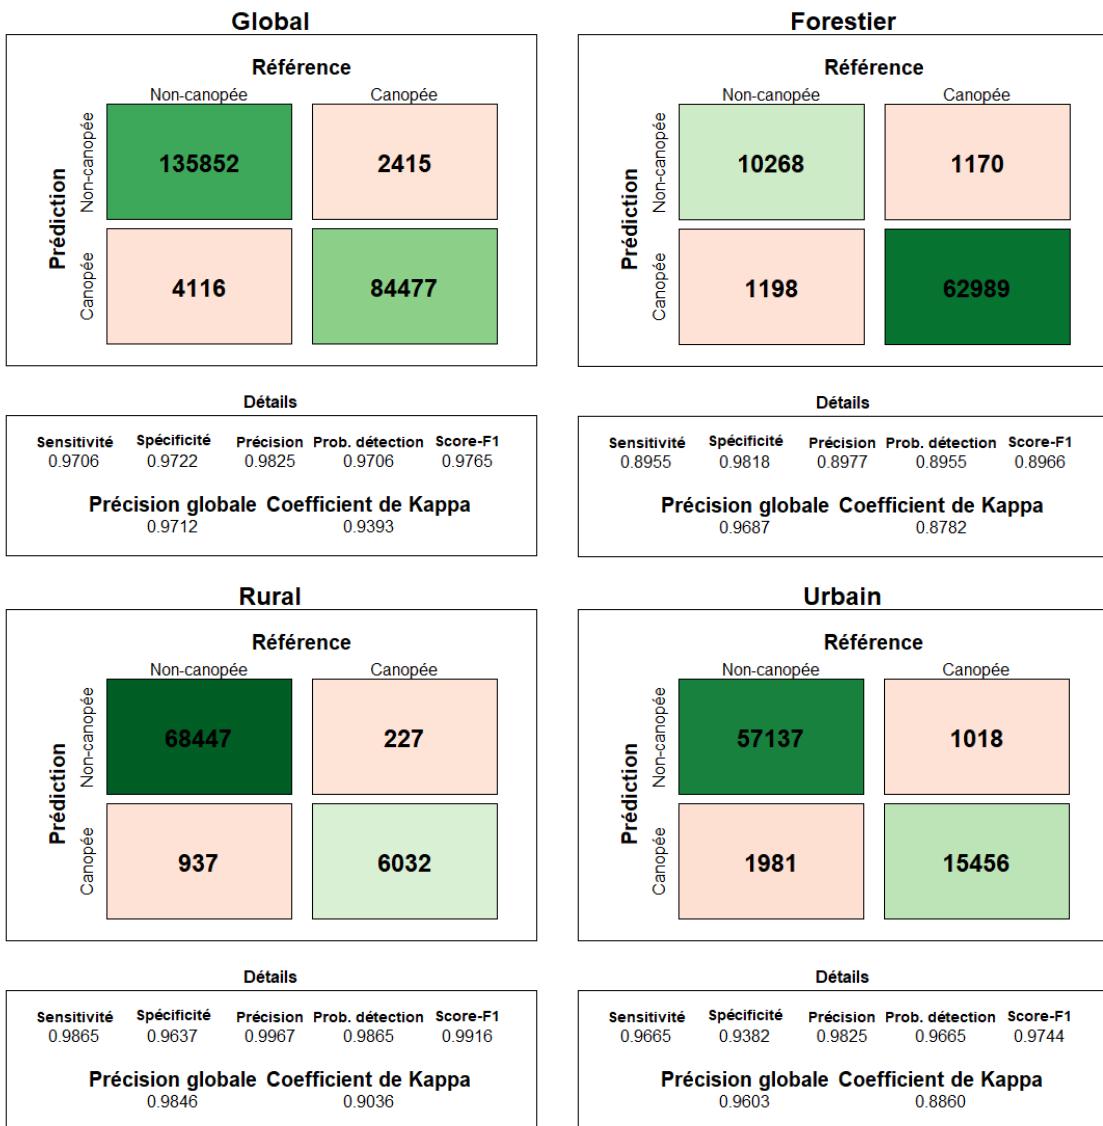


Figure 22. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Saguenay.

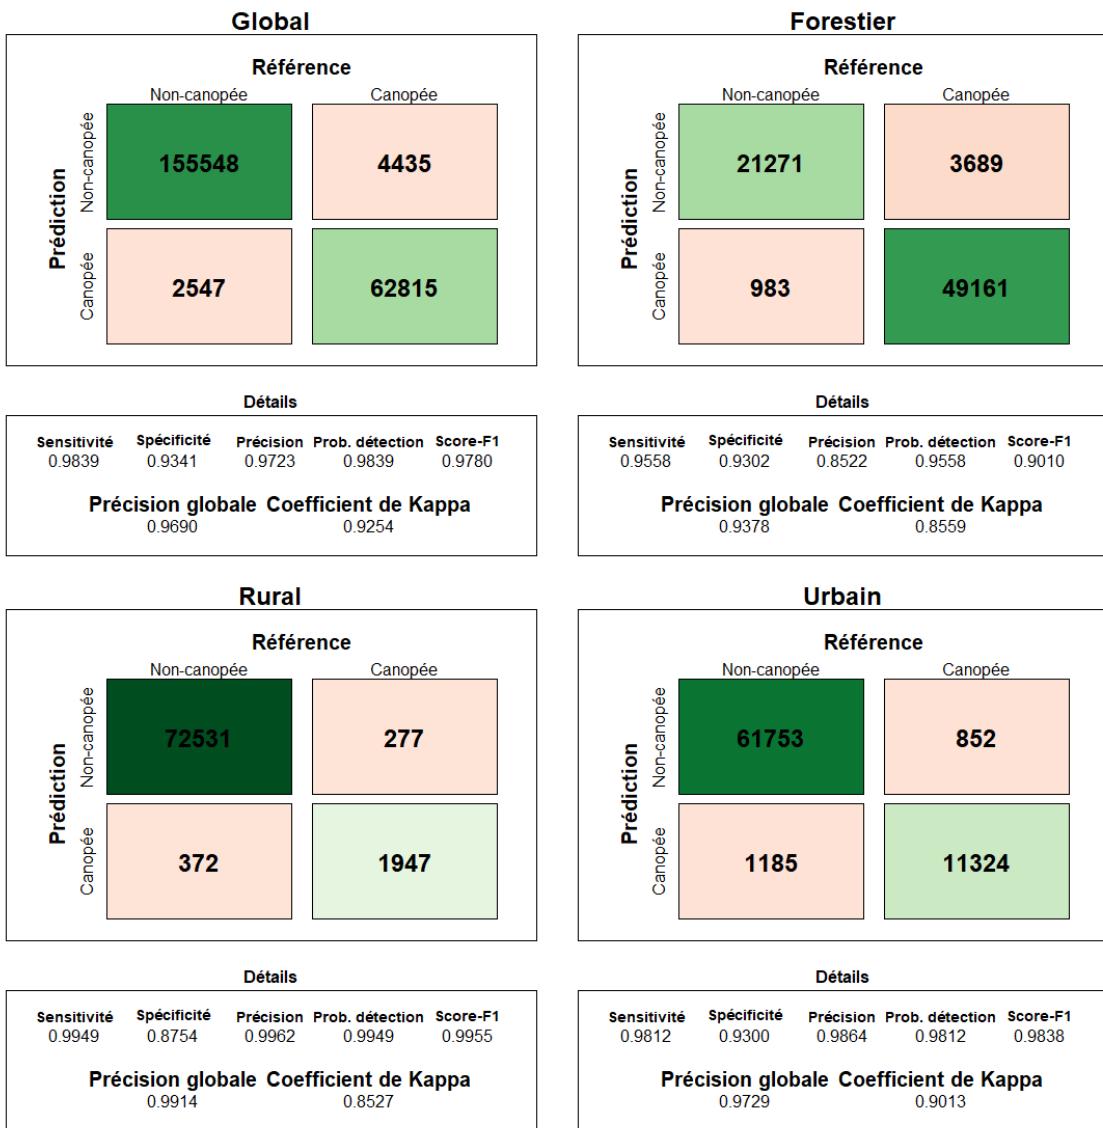


Figure 23. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) de la région métropolitaine de recensement de Trois-Rivières.

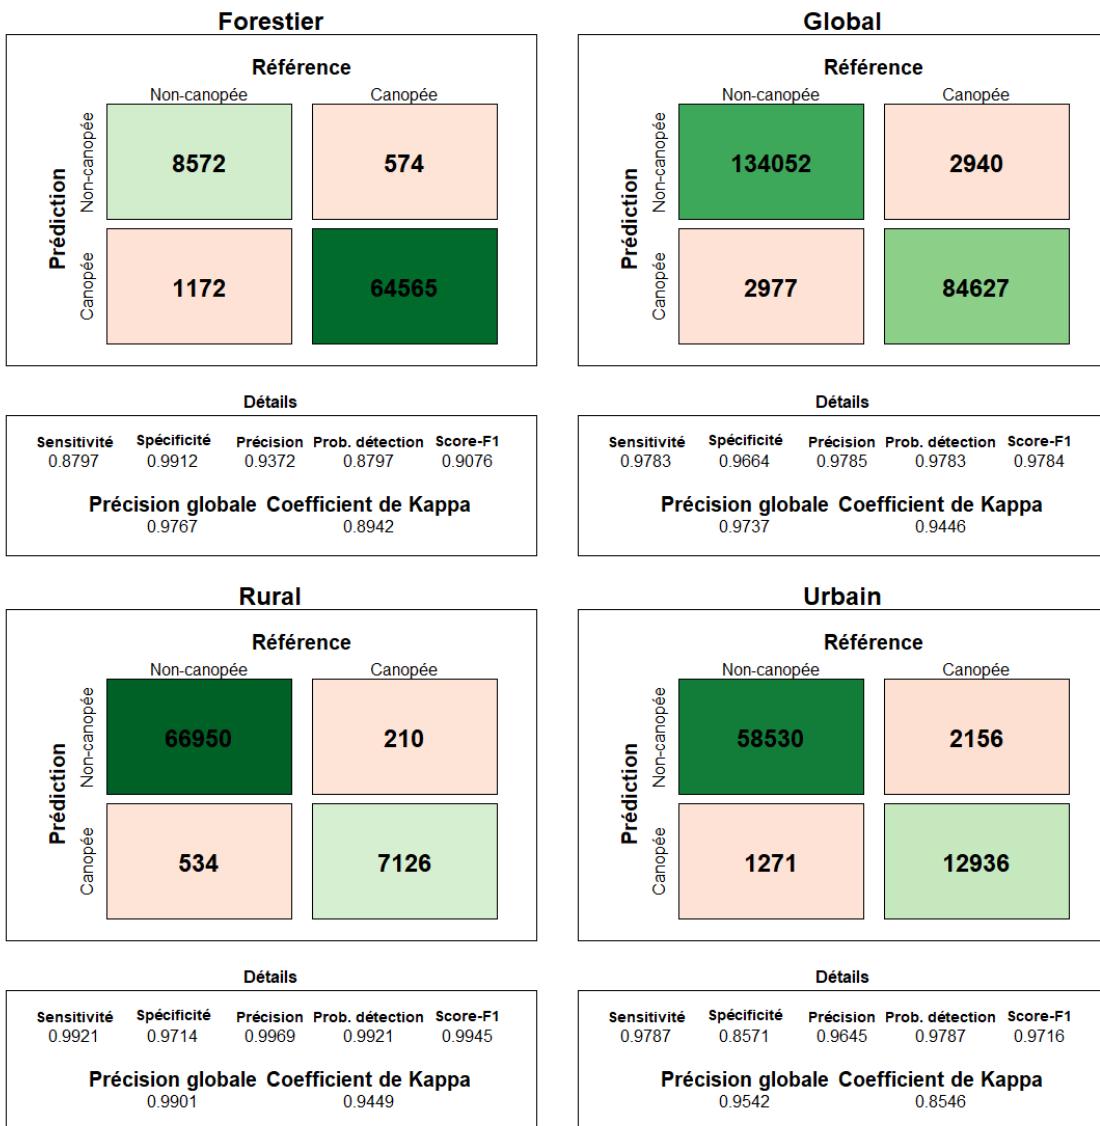


Figure 24. Matrices d'erreurs globales et par type d'environnement pour la canopée (nombre de pixels) des zones utilisant uniquement le modèle numérique de hauteur comme variable.

## 5.2. Indices de canopée

Les indices de canopée calculés par cellule montrent d'excellentes performances dans toutes les RMR, avec une corrélation entre les valeurs observées et prédites allant de 0,9747 dans la RMR de Sherbrooke (Figure ) à 0,9955 dans la RMR de Québec (Figure 26).

Les milieux forestiers présentent en général des valeurs d'indice de canopée élevées. La relation entre les valeurs observées et prédites est généralement similaire aux performances globales. Cependant les indices de canopée prédits dans la RMR de Trois-Rivières sont plus hauts que les valeurs observées, surtout dans les zones où ces dernières sont supérieures à 0,75.

En milieu rural, une majorité des observations présentaient de faibles valeurs d'indice de canopée. Les performances des prédictions sont similaires à celles observées globalement, et ce, pour toutes les RMR.

Dans le milieu urbain, les valeurs observées montrent plus de variations que dans les autres milieux. Les performances sont cependant très bonnes et présentent moins de variations entre les RMR que les autres milieux, avec des valeurs de  $R^2$  allant de 0,9581 pour la RMR de Gatineau (Figure 28) à 0,9901 pour la RMR de Québec (Figure 26).

Le modèle utilisant uniquement le MNH comme variable montre des performances similaires de façon globale, ainsi que dans les milieux forestiers et ruraux ( $R^2$  de 0,9799, 0,9780 et 0,9895 respectivement; Figure 31). Cependant, en milieu urbain les performances se dégradent ( $R^2 = 0,8181$ ; Figure 31) et présentent une nette tendance à la surestimation de l'indice de canopée.

Finalement, la comparaison pratiquée entre les prédictions effectuées entre les zones utilisant un lidar acquis avec l'absence ou présence de feuilles dans les arbres suggère une sous-estimation de l'indice de canopée en absence de feuilles, surtout dans les zones fortement boisées. Également en absence de feuilles, les valeurs observées/prédites sont plus dispersées qu'en présence de feuilles. Les performances restent toutefois très bonnes avec des valeurs de  $R^2$  de 0,9941 en présence de feuilles et 0,9848 en absence de feuilles.

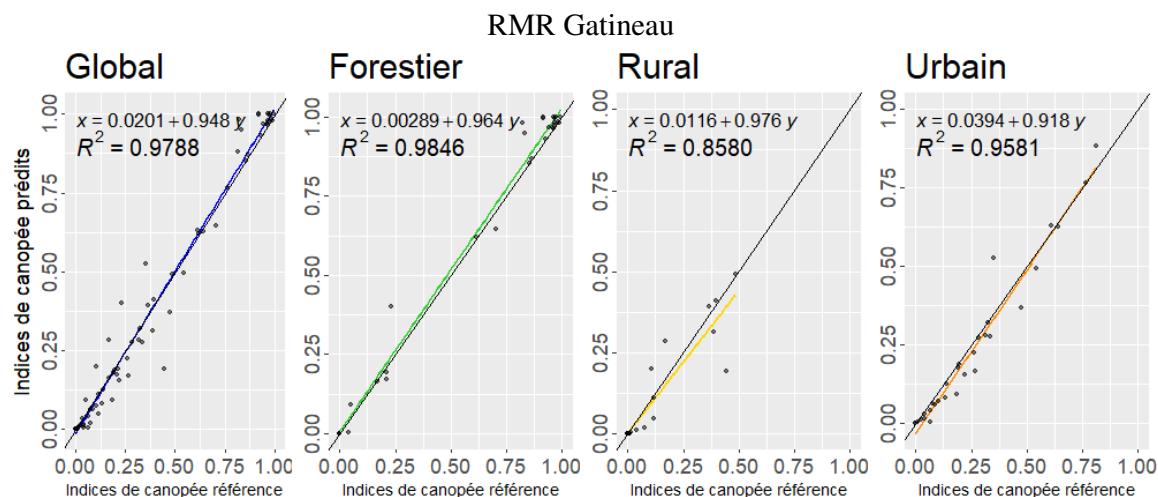


Figure 25. Comparaison entre les indices de canopée de référence et prédits par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Gatineau.

### RMR Québec

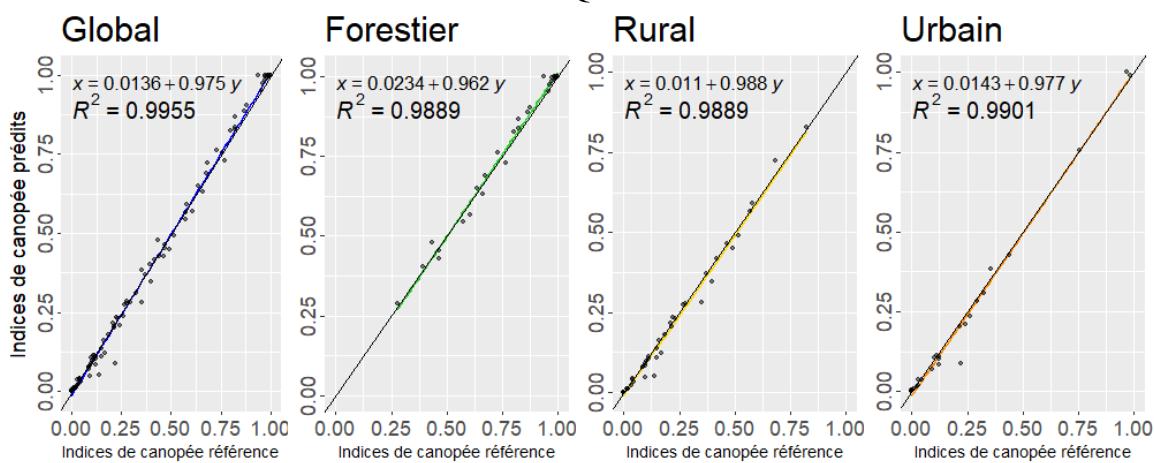


Figure 26. Comparaison entre les indices de canopée de référence et prédicts par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Québec.

### RMR Montréal

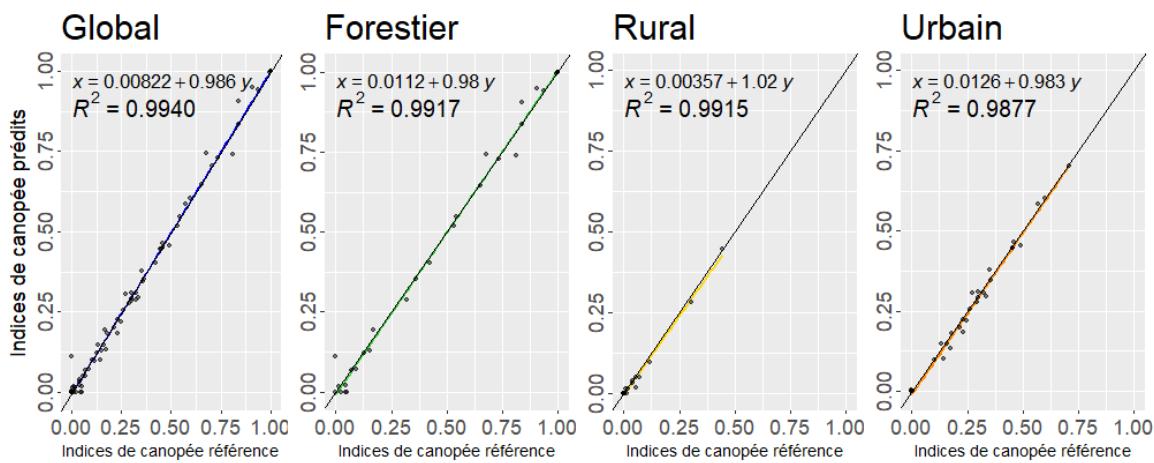


Figure 27. Comparaison entre les indices de canopée de référence et prédicts par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Montréal.

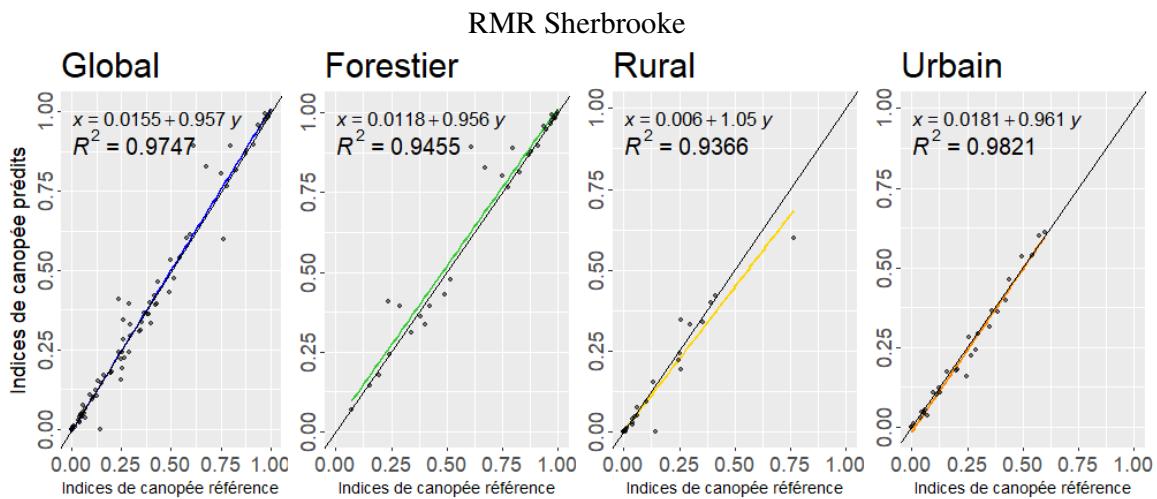


Figure 28. Comparaison entre les indices de canopée de référence et prédicts par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Sherbrooke.

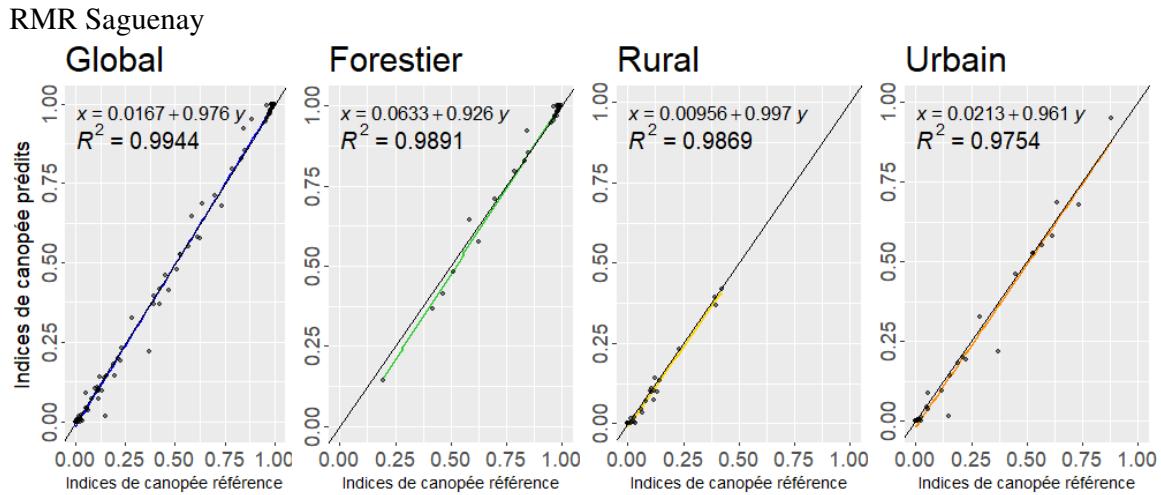


Figure 29. Comparaison entre les indices de canopée de référence et prédicts par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Saguenay.

### RMR Trois-Rivières

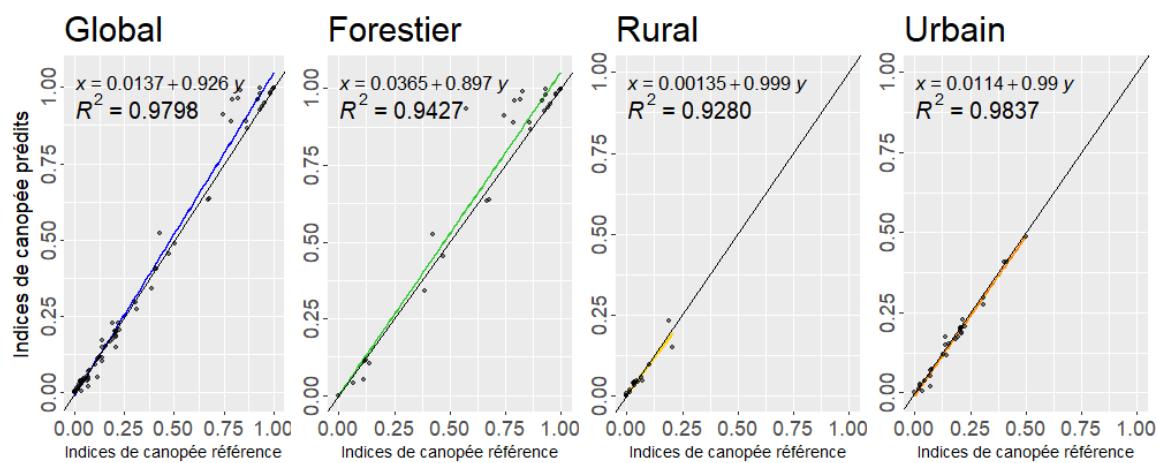


Figure 30. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour la région métropolitaine de recensement de Trois-Rivières.

### Modèle utilisant uniquement le M NH

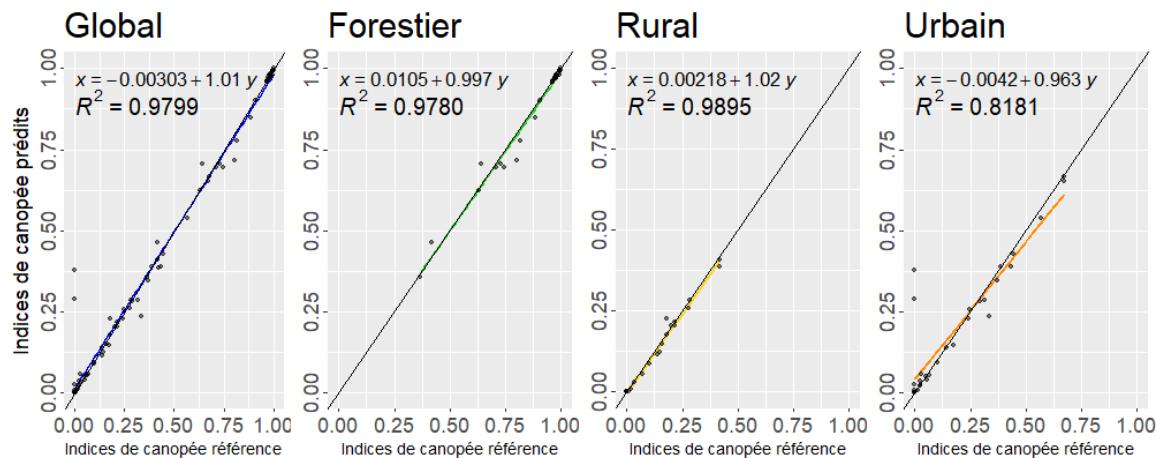
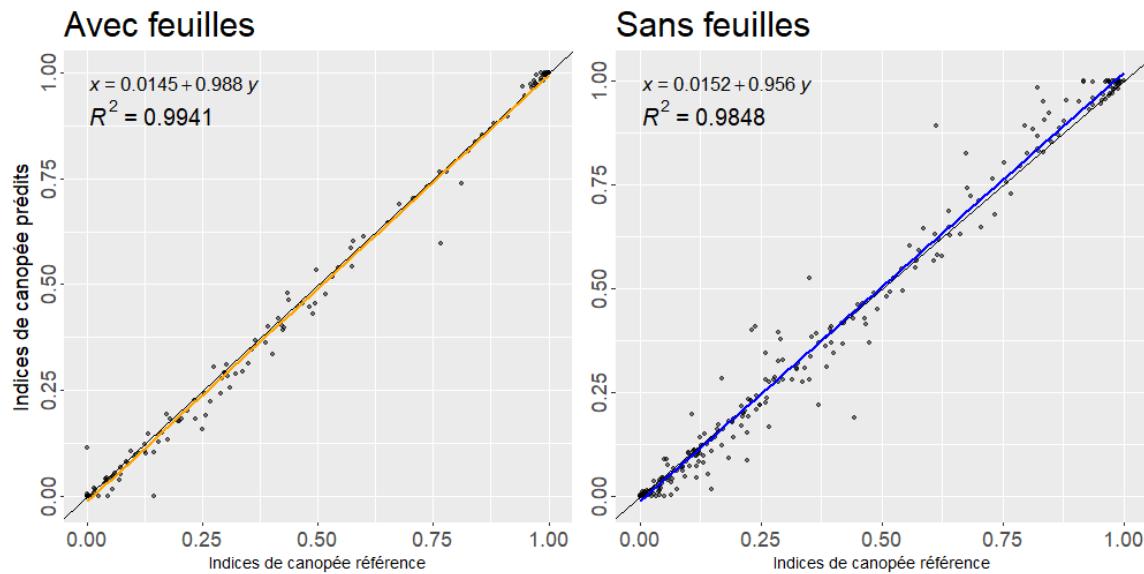


Figure 31. Comparaison entre les indices de canopée de référence et prédis par le modèle, globalement et par type de milieu, pour les secteurs utilisant uniquement le MNH comme variable prédictive.

## Présence ou absence de feuilles lors des acquisitions lidar



*Figure 32. Comparaison entre les indices de canopées de référence et prédis par le modèle, pour les acquisitions lidar réalisées lors de la présence et absence de feuilles.*

## 6. Discussion et conclusion

### 6.1. Performances générales

Plusieurs constantes peuvent être relevées pour donner suite à l'analyse des résultats :

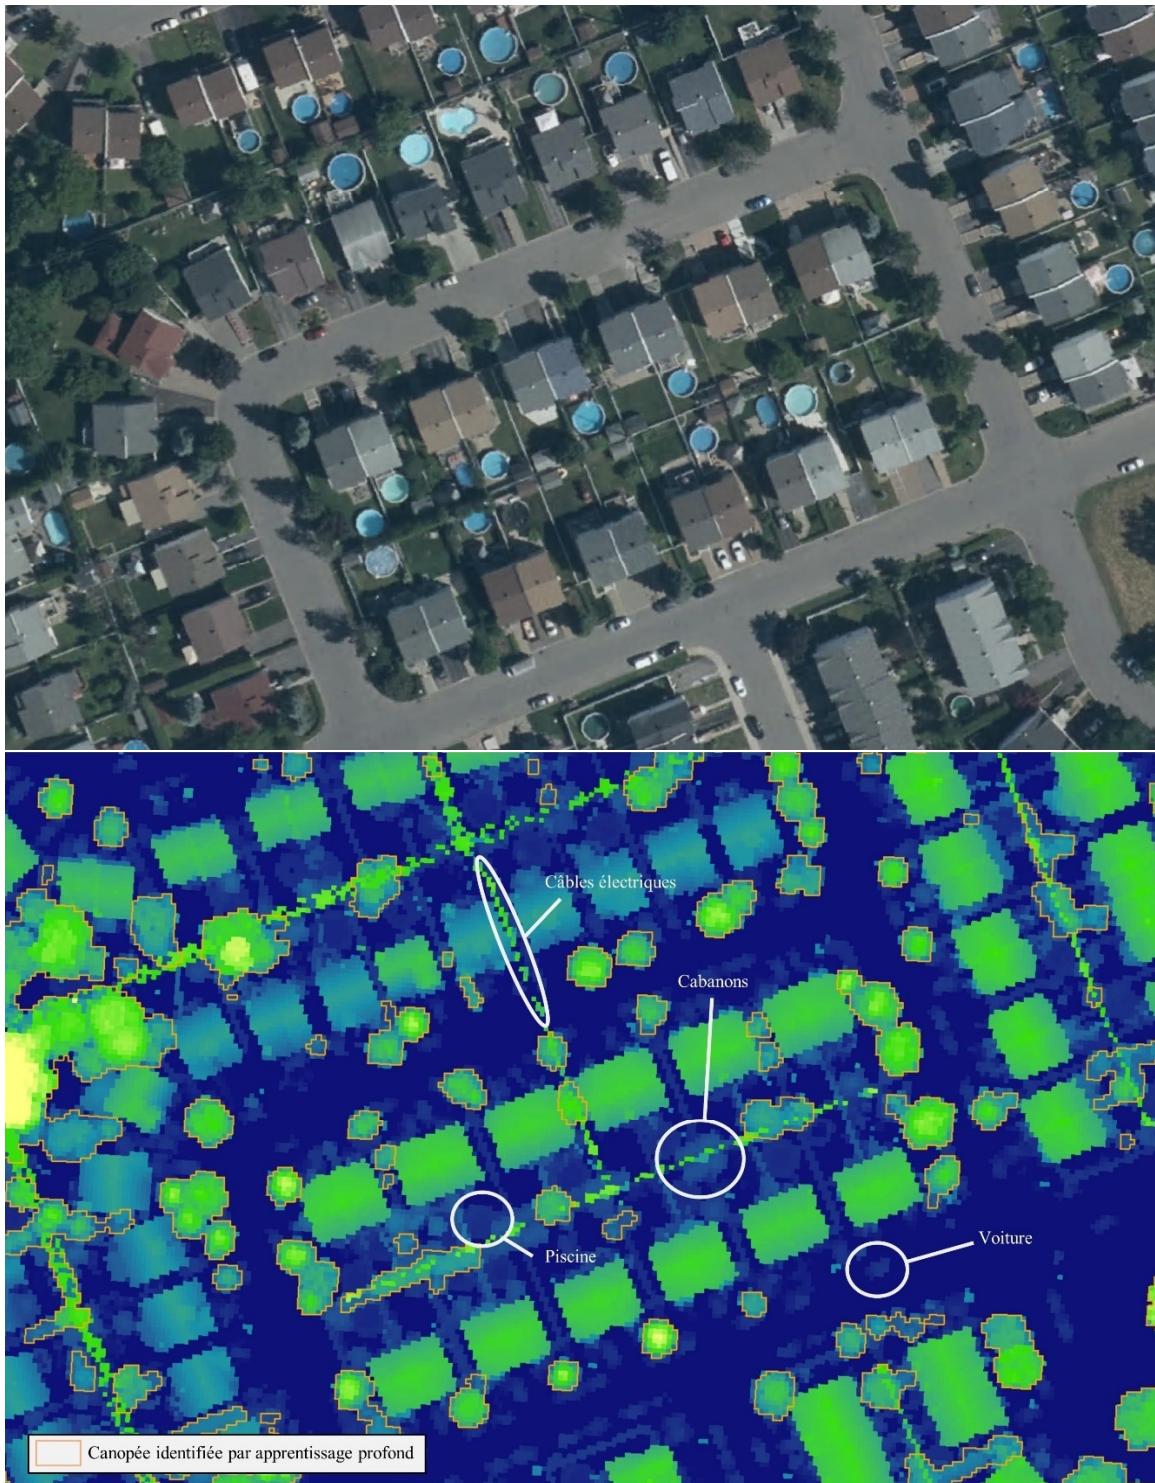
- Au travers des différents milieux dans lequel l'algorithme a été appliqué, la capacité à identifier la canopée est excellente (performances globales supérieures à 95 %). Le milieu urbain présente un grand nombre de structures dont les caractéristiques de hauteur peuvent ressembler à de la végétation (Figure 33), cependant la canopée prédictive exclue généralement ces structures ;
- À des fins de comparaisons, lorsqu'appliquées sur des données lidar similaires à celles utilisées pour réaliser la cartographie de la ville de Montréal en 2015, les prédictions par apprentissage profond arrivent à des résultats similaires (indice de canopée concordant à 75 % dans l'arrondissement de Lachine; Figure 43) et dans certains cas effectuent des corrections sur la donnée utilisée à la base comme référence (Figure 34) ;
- L'algorithme présente une bonne capacité pour identifier la canopée, autant dans le cas d'arbres uniques que dans le cas de grands boisés. Dans ces derniers, la présence de structures ponctuelles de non-canopée est généralement détectée, comme illustré dans la Figure 35 ;

- En milieu rural les prédictions semblent correspondre à la végétation présente, les performances calculées sur les indices de canopée pour ce milieu vont en ce sens. Cependant les statistiques des matrices d'erreurs ont tendance à présenter des valeurs de coefficient de Kappa plus basses que dans les autres milieux. Le milieu rural compte une faible superficie de canopée, étant donné l'usage agricole de ces terrains. Les classes de canopée et non-canopée étant dééquilibrées dans ce milieu, il est probable que les erreurs de classification aient un poids plus important dans les statistiques générales, ce qui peut expliquer les valeurs plus basses de coefficients de Kappa ;
- Bien que plusieurs années séparent la création de la canopée 2021 de la ville de Québec des données lidar disponibles (2017), les prédictions par apprentissage profond montrent visuellement beaucoup de similarités avec cette canopée (Figure 36). La canopée prédite par apprentissage profond présente cependant moins de petites entités isolées de végétation. Il est cependant nécessaire de préciser que la donnée de comparaison utilisée dans la Figure 36 (MNH) donne un avantage à l'algorithme d'apprentissage profond puisque la canopée 2021 de la ville de Québec a été cartographiée avec une image satellitaire de plus fine résolution spatiale (Varin *et al.*, 2020a).

La superficie de canopée, ainsi qu'un indice de canopée global a été compilé par RMR dans le Tableau 6, la méthodologie de calcul de l'indice de canopée est similaire à celle utilisée par Varin *et al.* (2020a) où la surface de canopée est comparée à la surface de l'aire d'intérêt sans prendre en compte les superficies d'eau libre. La RMR présentant l'indice de canopée global le plus élevé est Gatineau avec 75,9 % de canopée, tandis que la RMR de Montréal présente l'indice de canopée le plus bas avec 32,6 % de canopée.

*Tableau 6. Superficie de canopée et indice de canopée global par RMR.*

RMR	Superficie de canopée (km <sup>2</sup> )	Indice de canopée global
Gatineau	2250,6	75,9 %
Québec	2219,2	66,9 %
Montréal	1367,6	32,6 %
Sherbrooke	871,2	59,7 %
Saguenay	1812,4	71,9 %
Trois-Rivières	450,0	43,6 %



*Figure 33. Illustration avec le modèle numérique de hauteur et l'image aérienne de la capacité d'identification de canopée en milieu urbain présentant différentes structures de hauteur supérieure à deux mètres.*

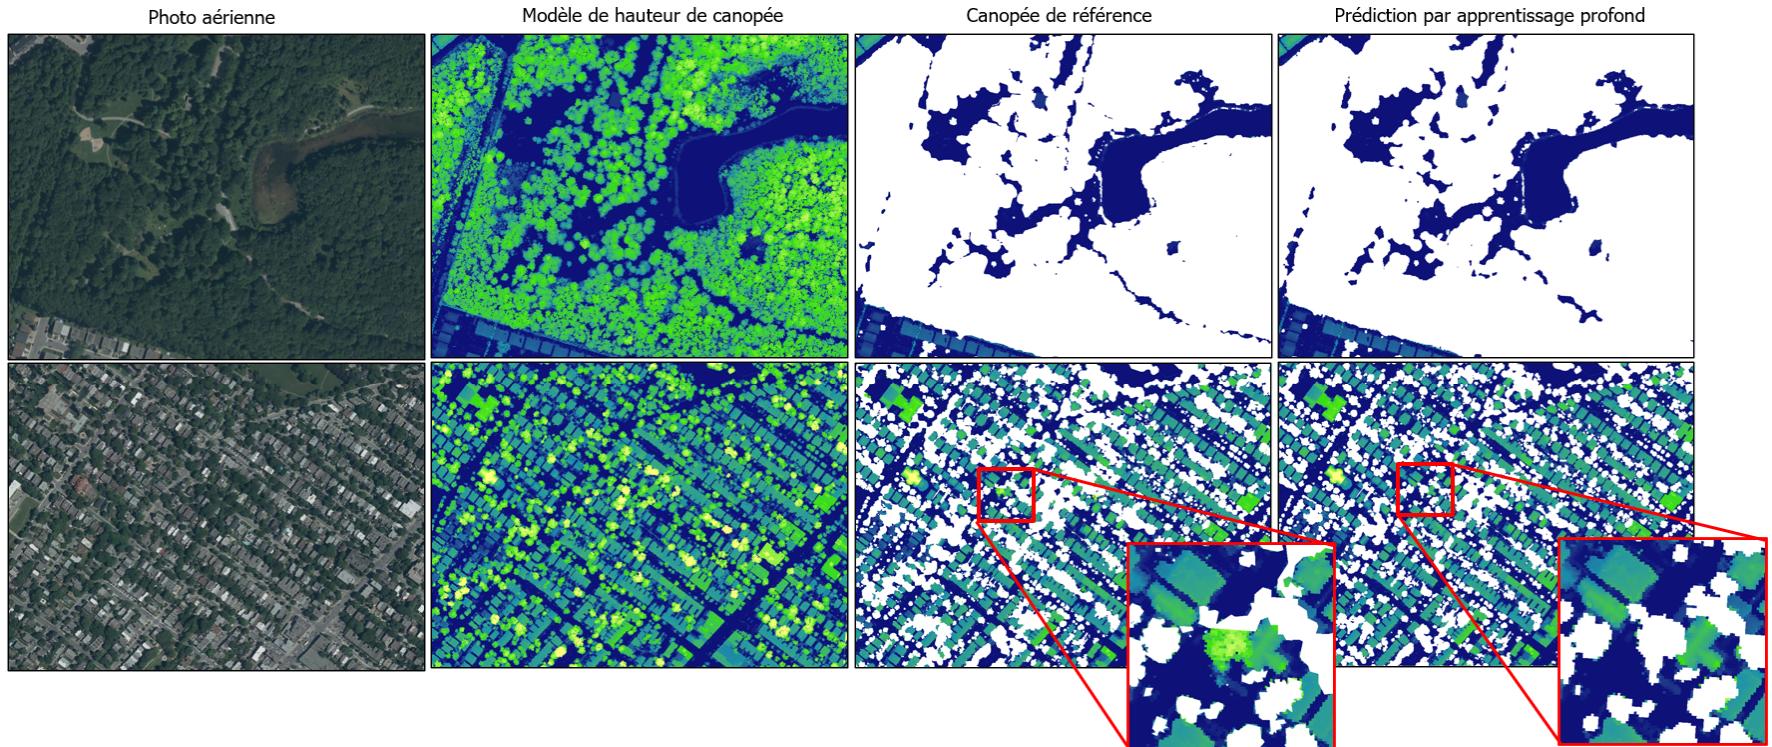


Figure 34. Comparaison dans la ville de Montréal entre images aériennes, modèles numériques de hauteur lidar 2015, canopée 2015 produite par la ville de Montréal et les prédictions du modèle par apprentissage profond.

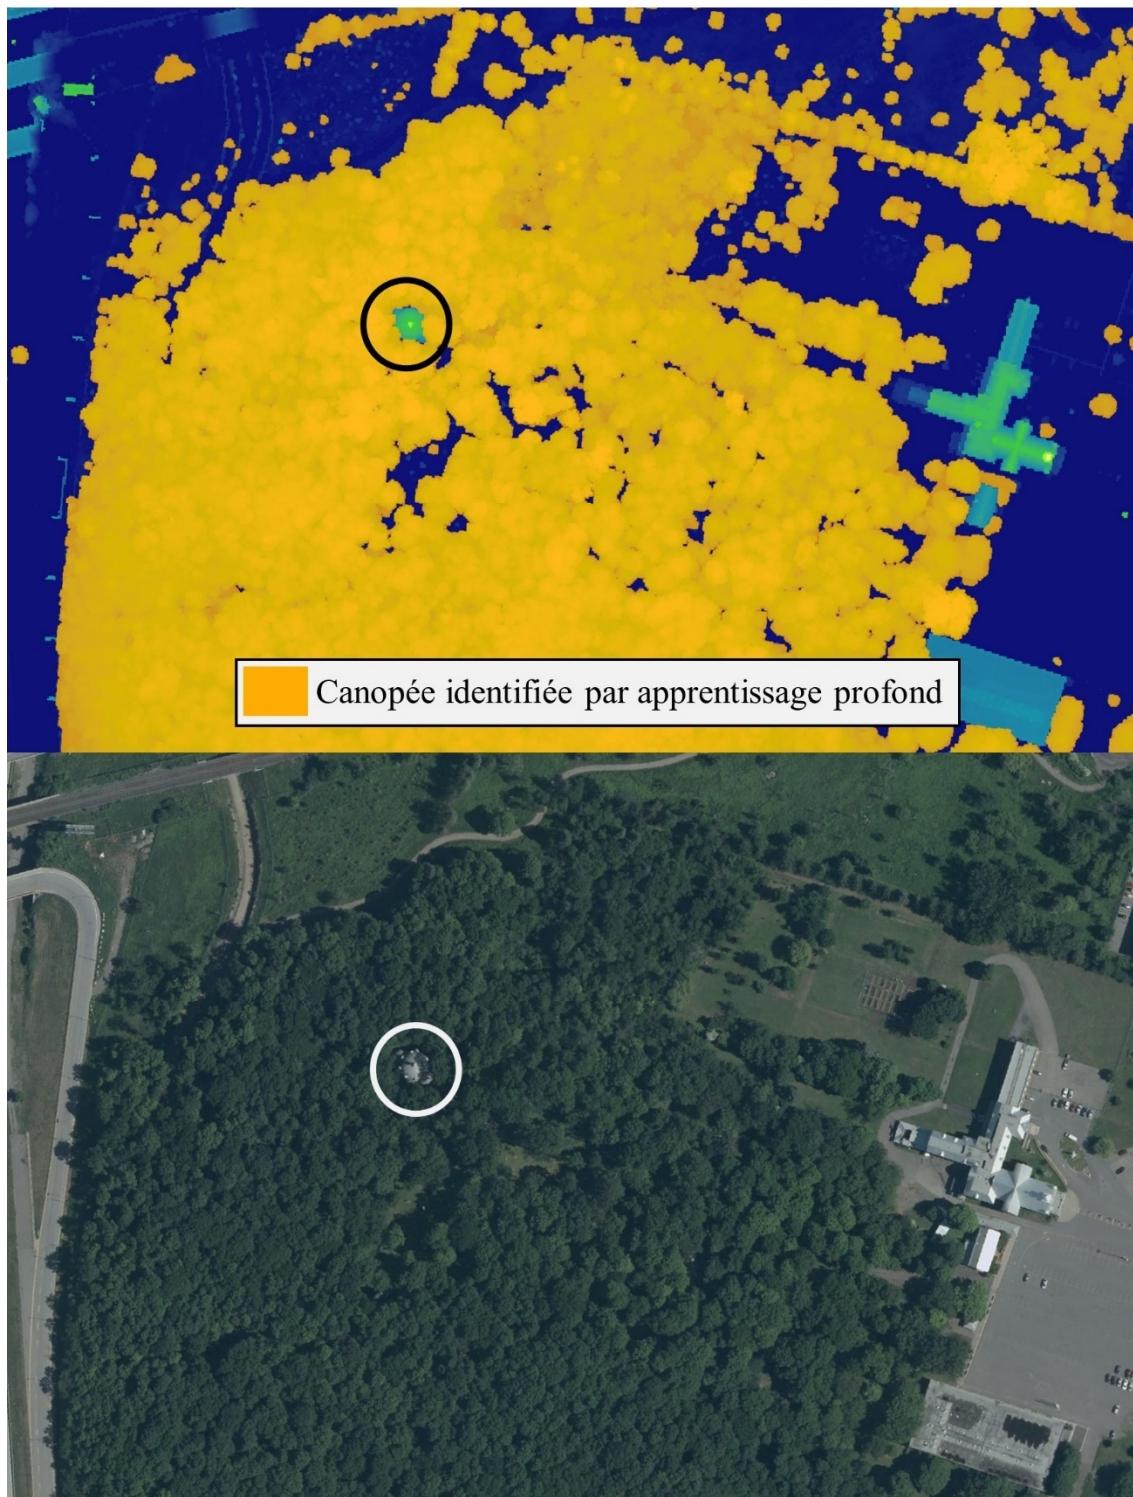


Figure 35. Illustration avec le modèle numérique de hauteur et l'image aérienne de la capacité de discernement de structures de non-canopée en milieu boisé.

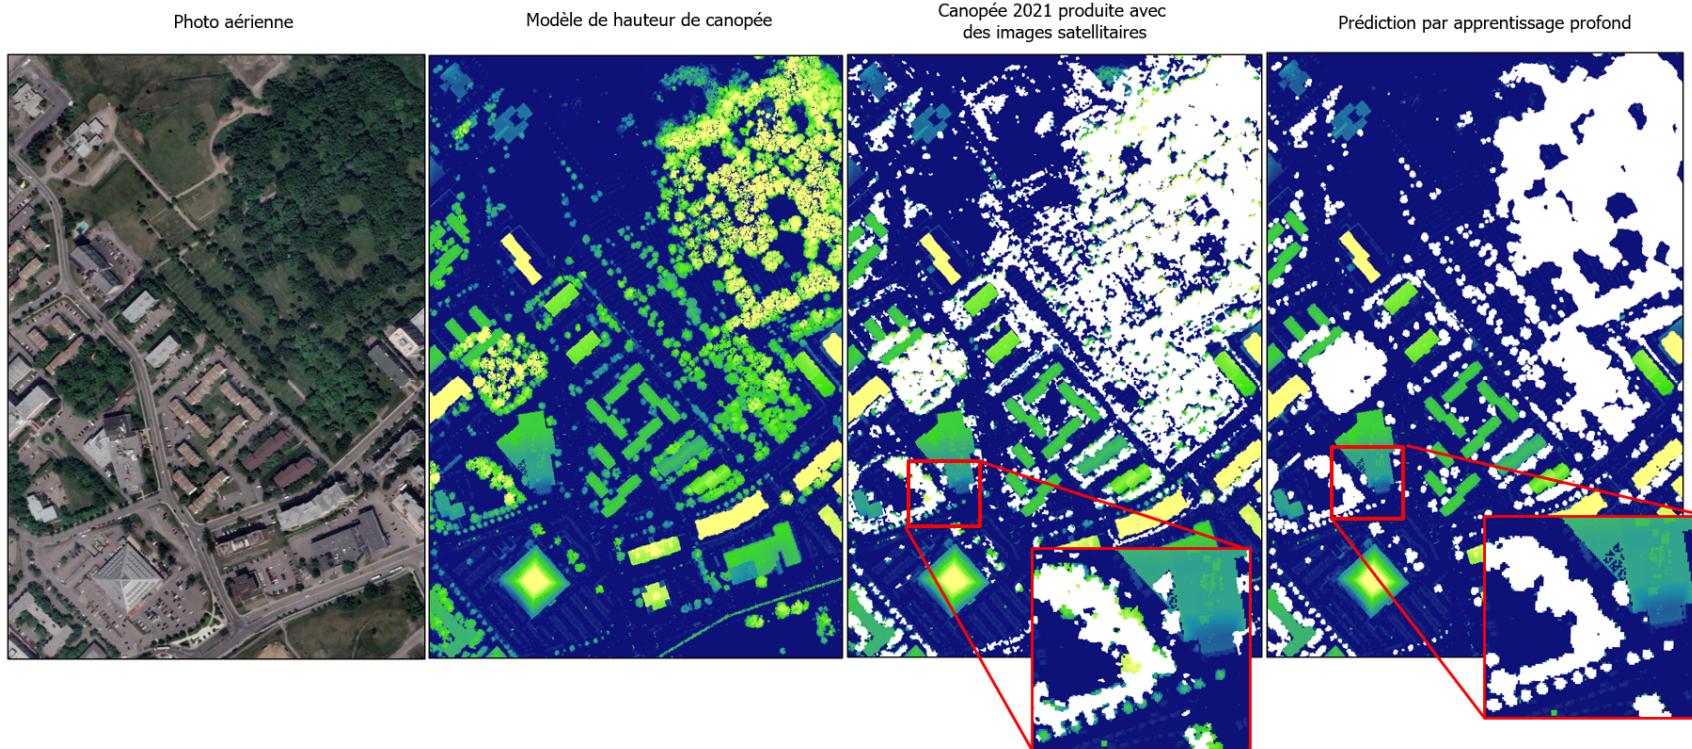


Figure 36. Comparaison dans la ville de Québec entre images aériennes, modèle numérique de hauteur lidar 2017, canopée 2021 produite avec des images satellites pour la ville de Québec et les prédictions du modèle par apprentissage profond; en blanc, la canopée prédictive.

## 6.2. Erreurs de commission

Des erreurs de commission ont été relevées dans la prédiction de canopée et sont généralement issues d'erreurs dans les données de référence, de similarité avec la végétation d'intérêt ou par la présence de nouveaux éléments jamais rencontrée par l'algorithme lors de son entraînement. Cette section illustre quelques cas de commissions identifiés.

- Commission avec les haies :

Les haies sont des structures végétales, généralement linéaires et de forme rectangulaire, souvent entre 2 et 3 m de hauteur, ce qui diffère des caractéristiques des arbres. Les haies n'ont initialement pas été présentes lors de l'entraînement de l'algorithme. Les données de référence utilisées à la base (canopée de la ville de Montréal) ne présentent que très peu de ces structures végétales. Bien qu'un effort ait été mis pour éliminer les confusions entre les haies et d'autres structures non végétales, quelques artefacts ont été observés dans la donnée finale prédite ;

- Les véhicules de taille importante :

Les véhicules récrétouristiques, ainsi que de hauts véhicules ont déjà été identifiés comme étant une cause de commission pour l'algorithme puisqu'ils partagent des formes et hauteurs similaires à celles d'une haie (Figure 37, I et II) ;

- Les cabanons :

Les cabanons de jardin, souvent placés dans le fond des terrains résidentiels, sont généralement adossés à une haie, tout en présentant des caractéristiques de hauteur similaire. À la suite de plusieurs itérations lors de la création des algorithmes, ces erreurs sont plutôt rares dans la donnée finale prédite ;

- Bateaux :

Très peu de zones nautiques étaient présentes dans les données de référence. Les bateaux, de par la hauteur des mâts et des éléments présents en hauteur (câbles, voile, etc.), présentent des caractéristiques de hauteur similaires à des arbres. Aucun bateau, ou très peu, n'ont été présentés à l'algorithme lors de son entraînement. Les grandes étendues d'eau (i.e. Fleuve Saint-Laurent, Fjord du Saguenay) sont toutefois exclues des RMR. Il n'est pas impossible de retrouver ce type de commission dans la donnée finale prédite, mais leur occurrence reste rare ;

- Toits de très hauts bâtiments :

Quelques erreurs ont été identifiées au sommet de grandes tours, comme celles présentes dans le centre-ville de Montréal. Bien que ces zones aient été incluses dans les données d'entraînement dès le début de la création des algorithmes, leurs occurrences sont faibles relativement au reste du territoire et peuvent induire des erreurs d'interprétation de la part de l'algorithme. Les observations réalisées de ce type d'erreur cumulent au plus une dizaine de  $m^2$  de canopée faussement identifiée. Considérant la faible abondance de très grandes tours dans les RMR, ce type d'erreur peut être considéré comme extrêmement rare ;

- Zones industrielles :

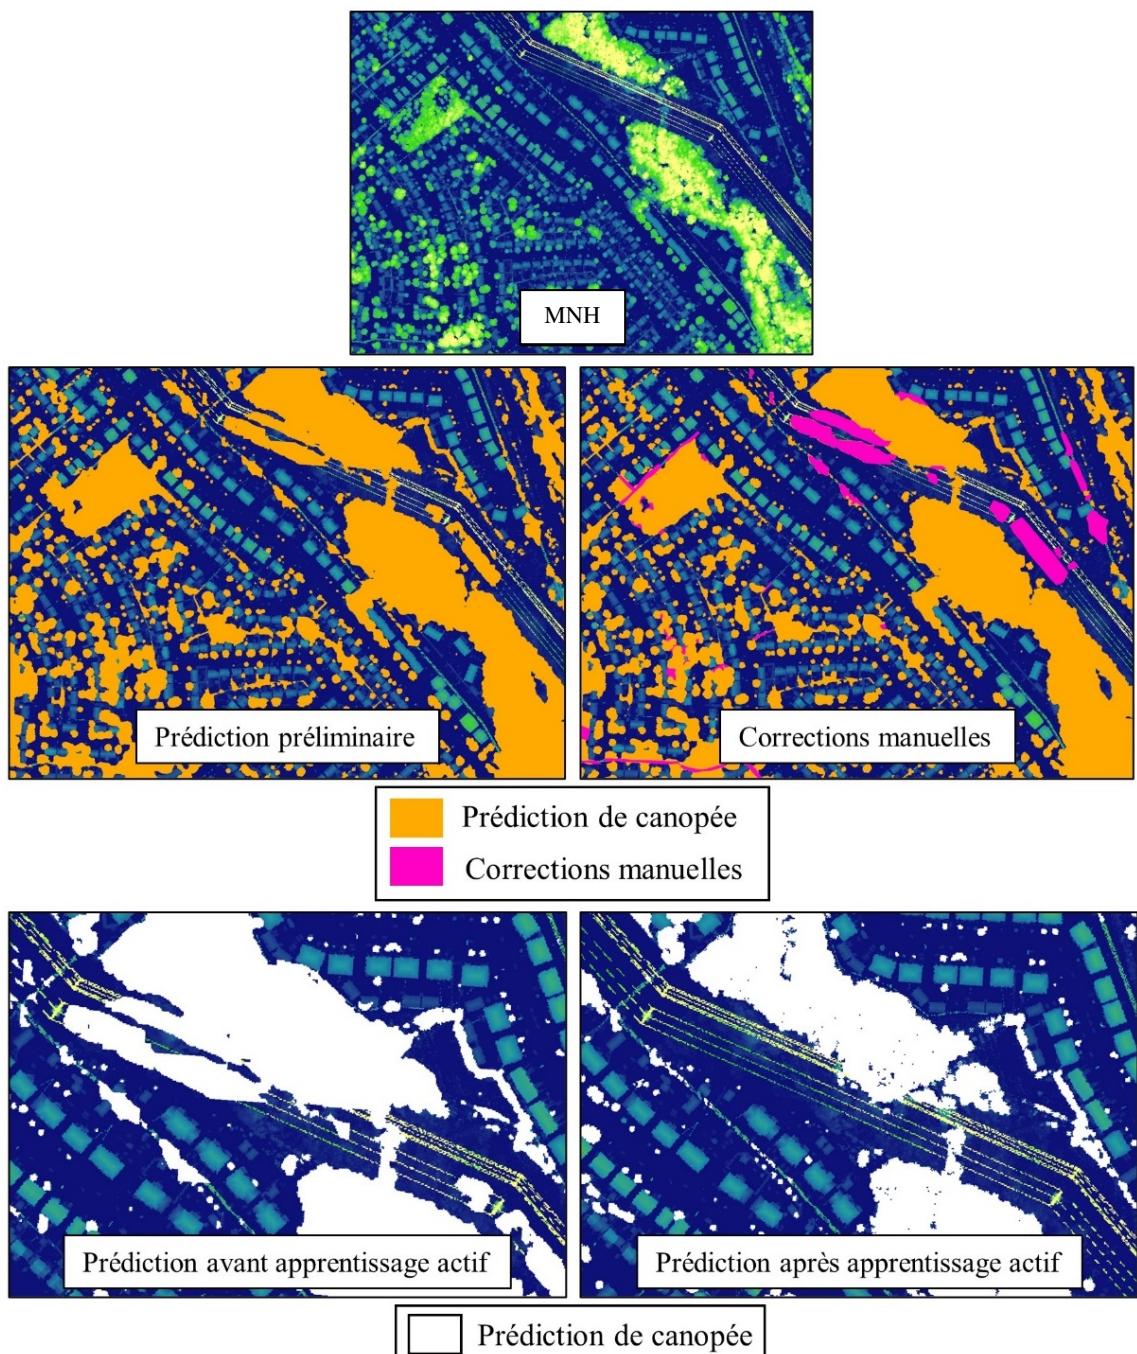
Bien que plusieurs zones industrielles soient présentes dans les données de base utilisées sur l'île de Montréal, il existe un grand nombre de configurations d'usines n'étant pas forcément toutes présentes dans les données d'entraînement. Des erreurs de commission ont été identifiées en premier dans des raffineries, qui présentent une forte abondance de tuyaux placés en hauteur et se traduisant donc par des structures ressemblant à des haies ou présentant une hauteur et un écart-type similaires à un arbre (du fait des retours lidar arrivant jusqu'au sol entre les tuyaux). Ces erreurs ont rapidement été identifiées et des zones présentant ces caractéristiques ont été ajoutées dans les données pour éliminer ce type d'erreur.

- Réseau de distribution d'électricité :

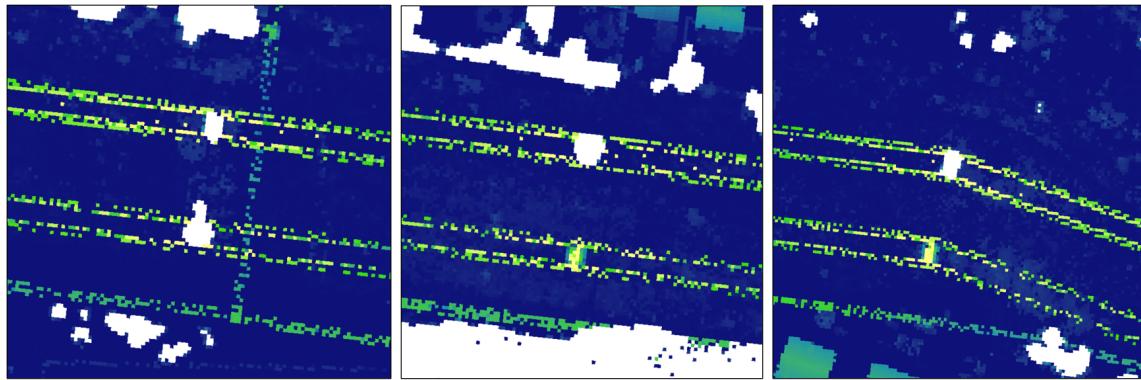
Éviter la commission liée à la présence d'infrastructure du réseau de distribution d'électricité fut un défi. Ces structures étaient très présentes dans les données d'entraînement, cependant de la végétation est souvent présente sous les câbles électriques et les pylônes des lignes de haute tension. De ce fait, les structures du réseau de distribution d'électricité étaient souvent identifiées dans les données d'entraînement comme étant de la végétation (Figure 38 et Figure 39). Le processus d'apprentissage actif, comme illustré dans la Figure 38 a permis de réduire grandement ce type d'erreur. Malgré les efforts déployés pour éliminer ces erreurs de commission, elles sont encore présentes dans la donnée finale prédictive (Figure 37, III). Parmi les types d'erreurs de commission, les câbles électriques sont les plus communs, leur occurrence reste toutefois très faible.



Figure 37. Illustration avec le modèle numérique de hauteur et l'image aérienne d'erreurs de commission relevées (I. Véhicules récréatifs, II. Groupement de véhicules, III. Câbles électriques).



*Figure 38. Illustration des étapes d'apprentissage actif réalisées pour réduire les erreurs de commission associées au réseau de distribution d'électricité. MNH : modèle numérique de hauteur.*



*Figure 39. Exemples de commission sur des pylônes du réseau de distribution d'électricité, en blanc la canopée prédite.*

### 6.3. Erreurs d'omission

Des erreurs d'omission ont été relevées dans la prédiction de canopée, il s'agit donc d'arbres réellement présents sur le territoire, mais non prédis dans la donnée finale. Cette section illustre quelques cas d'omission identifiés.

- Arbres surélevés :  
Essentiellement présents dans le centre-ville de Montréal, des arbres disposés sur des terrasses surélevées ont parfois été manqués par l'algorithme. Cette disposition est très rare, autant dans les données d'entraînement que dans les données à prédire ;
- Très petits arbres :  
Les variables lidar ayant été calculées à une résolution de 1 m, les arbres ne couvrant pas plus de  $1 \text{ m}^2$  n'étaient représentés que par 1 pixel. Il n'a pas été possible d'identifier ces arbres avec la résolution à disposition ;
- Boisés épars et boisés denses :  
L'algorithme a montré quelques difficultés à détouurer correctement des boisés de faible densité alternant végétation arbustive et arborescente (Figure 40). Les objets de très faible superficie ont tendance à être écartés des prédictions et l'alternance entre une végétation de hauteur importante et moyenne semble être perçue comme un élément autre que de la végétation ;  
Lors de la création des algorithmes, certains boisés denses où la couronne des arbres présentait un faible relief n'étaient pas toujours identifiés comme de la canopée. Ces attributs qui diffèrent de la majorité des arbres ont été ajoutés dans les données d'entraînement lors de sélections de données supplémentaires et ont permis de corriger la majorité de ces erreurs ;

- Contour des arbres :

La précision de la délimitation des arbres diffère d'un arbre à un autre. Dans la majorité des cas la délimitation est correctement réalisée (Figure 41, II et IV). Cependant la délimitation est parfois trop contrainte et certains pixels en périphérie de couronne ne sont pas inclus (Figure 41, I et III). La présence ou absence de feuilles lors de l'acquisition des données lidar ne semble pas avoir d'effet puisque des arbres mal délimités sont retrouvés dans les deux configurations (Figure 41). Ces artefacts peuvent provenir du passage de 3 à 2 m comme seuil de hauteur.

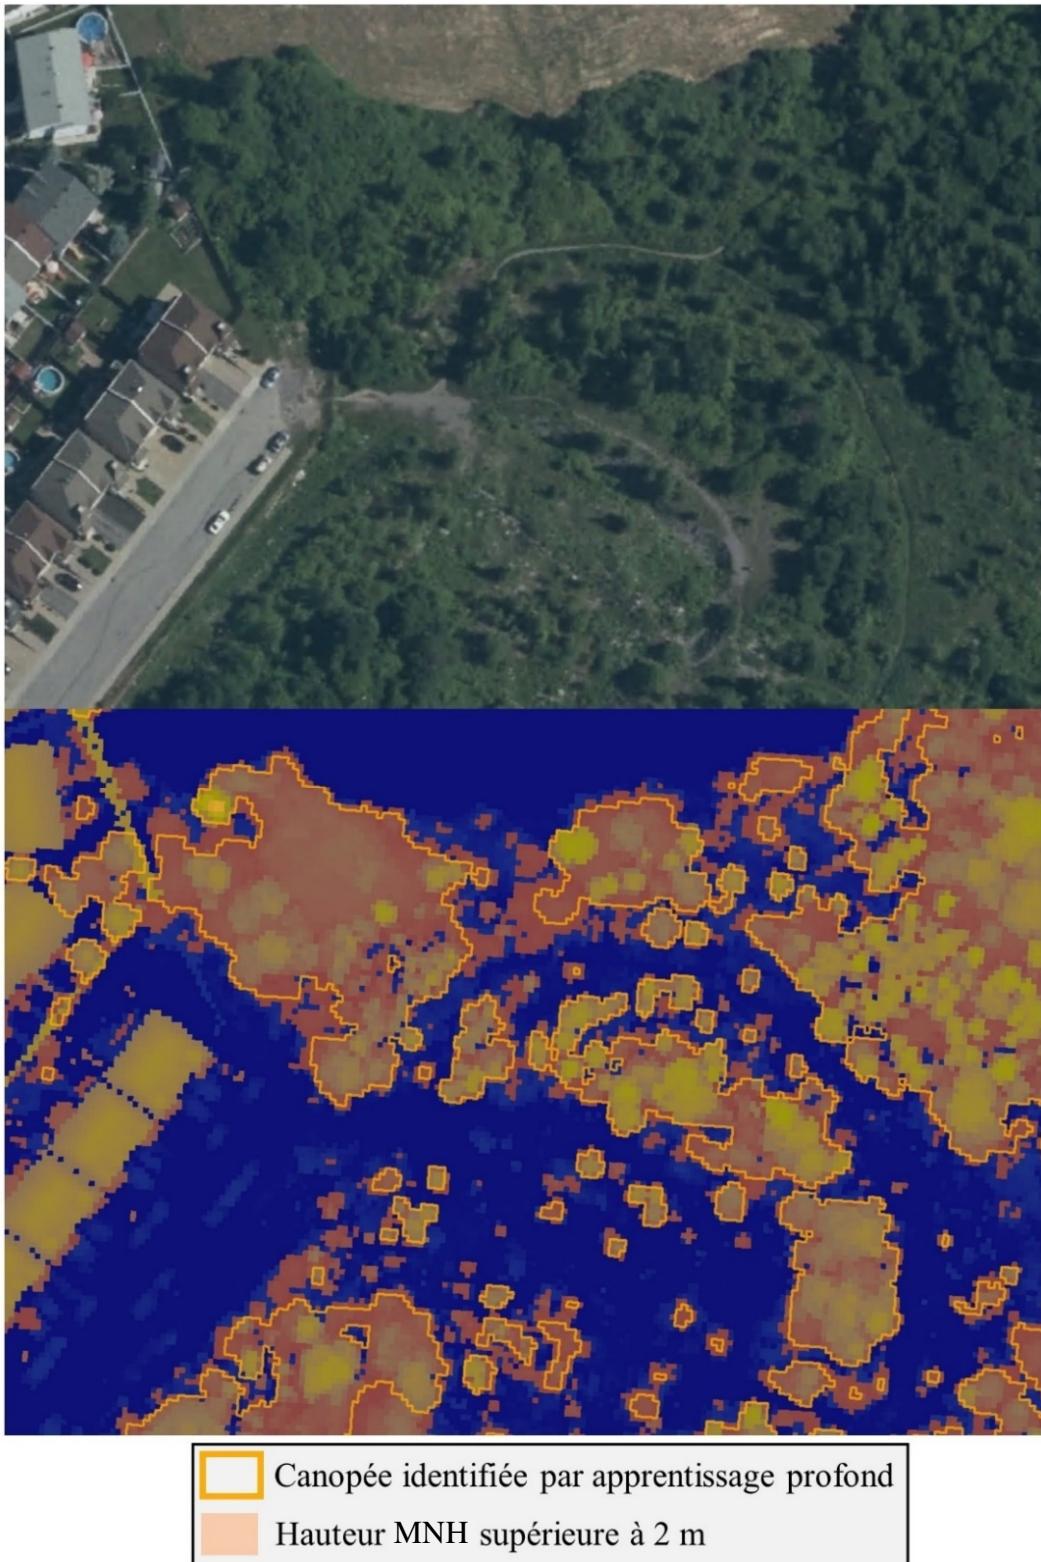
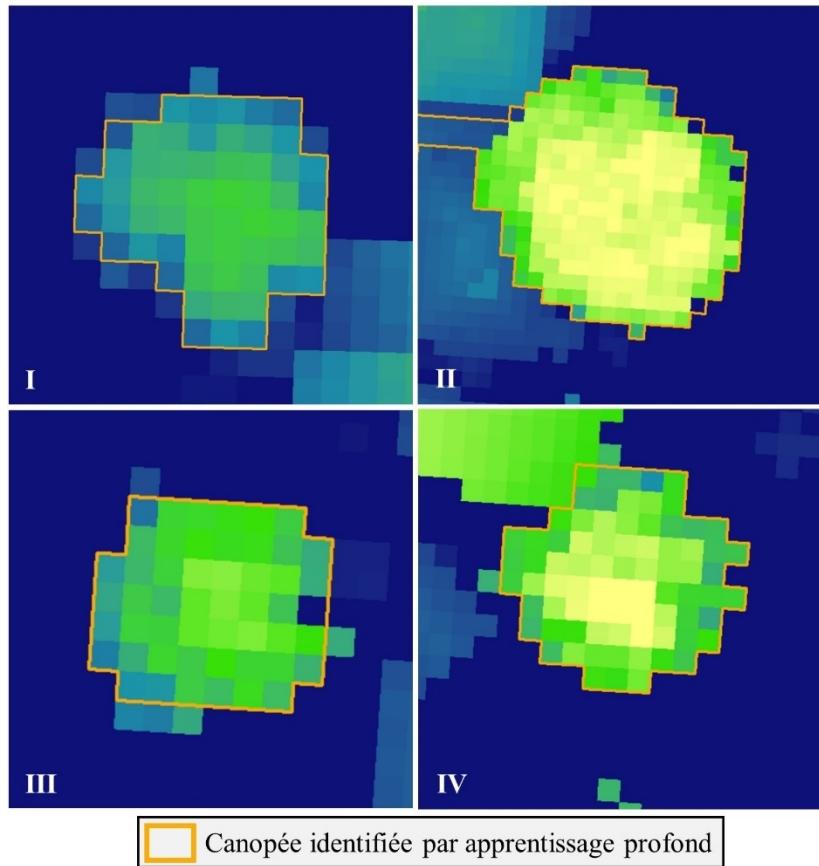


Figure 40. Illustration avec le modèle numérique de hauteur (MNH) et l'image aérienne d'erreurs d'omission pouvant apparaître dans les boisés diffus.



*Figure 41. Délimitation d'arbres uniques dans plusieurs configurations : I. Arbre dont la délimitation est trop contrainte (lidar avec feuilles) ; II. Arbre correctement délimité (lidar avec feuilles) ; III. Arbre dont la délimitation est trop contrainte (lidar sans feuille) ; IV. Arbre correctement délimité (lidar sans feuille).*

#### 6.4. Cas du modèle utilisant uniquement le modèle numérique de hauteur

Les prédictions issues du modèle utilisant uniquement le MNH présentent des performances intéressantes (précision globale = 0,9737; kappa = 0,9446) et l'indice de canopée correspond bien, de façon globale, à une mesure manuelle ( $R^2 = 0,9799$ ).

Dans tous les milieux (forestier, rural, urbain), des erreurs sont équitablement retrouvées, autant en omission qu'en commission. La correspondance entre l'indice de canopée prédit et mesuré manuellement est nettement moins bonne qu'avec les modèles utilisant plusieurs variables lidar. En milieu urbain, les erreurs de commission détaillées dans la section 6.2 sont plus souvent présentes, particulièrement pour les câbles électriques.

L'utilisation du MNH seul pour identifier la canopée constitue néanmoins une très bonne alternative à l'absence de données lidar brutes. Les plus basses performances montrent toutefois que les autres variables apportent une information très pertinente pour distinguer les éléments de non-végétation des éléments de végétation.

## **6.5. Effet de l'absence ou présence de feuilles lors des acquisitions**

La présence ou absence de feuilles dans les arbres lors de l'acquisition lidar a un effet non négligeable sur les données, tel qu'illustré dans la Figure 42. En présence de feuilles, la canopée des arbres occupe une superficie plus importante que sans feuille.

La comparaison des indices de canopée prédits et mesurés manuellement montre quelques disparités entre les données sans et avec feuilles. La tendance de l'algorithme à sous-estimer l'indice de canopée peut provenir de la donnée de validation. En effet, il est facile pour un photo-interprète de voir un arbre dans son ensemble et de l'identifier tel quel, tandis que l'algorithme pourrait avoir tendance à détourer chaque branche de l'arbre. On constate également une dispersion plus importante autour de la relation parfaite en absence de feuilles (Figure 32).

De façon générale, l'algorithme est capable d'identifier la présence d'un arbre qu'il y ait ou non des feuilles dans sa couronne. Cependant la superficie occupée par l'arbre sera influencée.

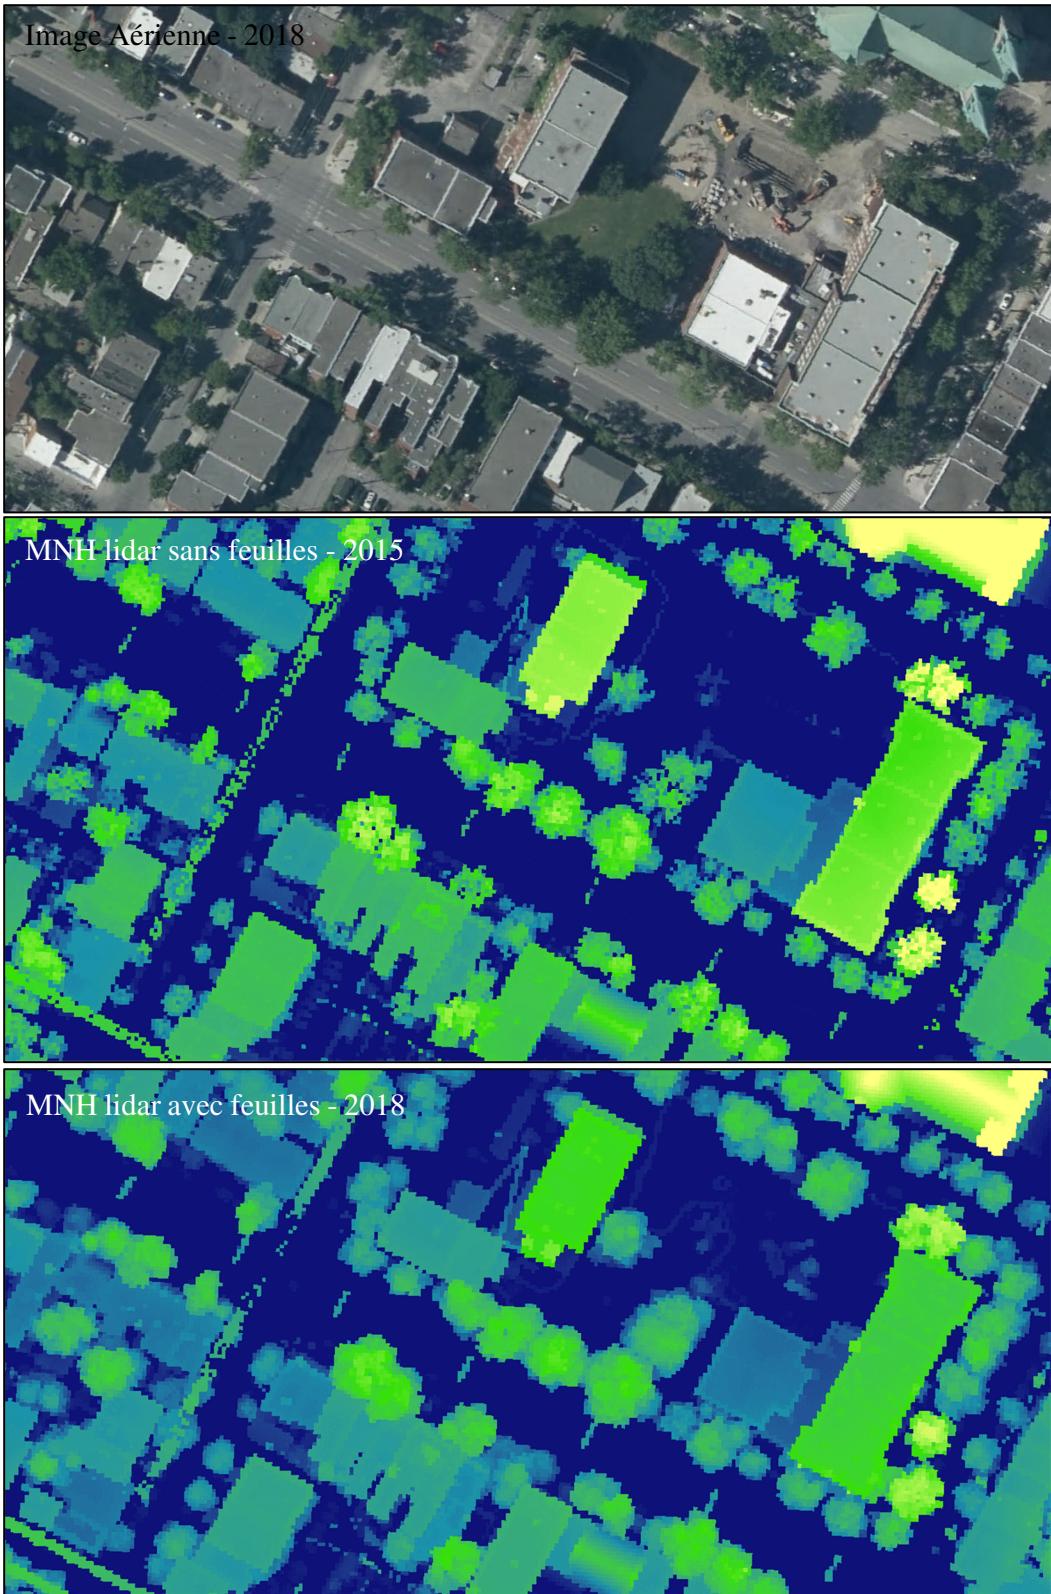


Figure 42. Comparaison de modèles numériques de hauteur calculés sur l'île de Montréal avec des données lidar acquises sans et avec feuilles.

## **6.6. Méthode de validation**

L'identification manuelle de 90 cellules par RMR a demandé un temps conséquent. Ces données ont été utilisées pour valider la canopée. L'interprétation de la canopée lors de la création des données de validation peut être la source d'un biais. Par exemple, une trouée de 2 m<sup>2</sup> au milieu d'un boisé n'aura pas d'influence sur la quantité d'ombre produite par les arbres. Cette trouée aurait donc été considérée comme faisant partie de la canopée environnante. Cependant les prédictions de l'algorithme pourraient identifier ce 2 m<sup>2</sup> comme de la non-canopée et ainsi créer une disparité avec la donnée « de référence ». Ces disparités peuvent avoir un effet non négligeable dans des secteurs avec peu de canopées, tel que le milieu rural, qui présente souvent les plus faibles performances.

## **6.7. Exemple de comparaison de canopées**

À des fins de démonstration, une comparaison de l'indice de canopée de l'arrondissement de Lachine à Montréal a été réalisée (18,5 km<sup>2</sup>). Puisque la canopée produite par la ville de Montréal a été réalisée avec une hauteur minimum de 3 m, il a été nécessaire d'exclure les pixels identifiés par apprentissage profond comme étant de la canopée dont la hauteur était inférieure à 3 m.

Les statistiques d'indice de canopée sont présentées dans la Figure 43 et montrent une différence notable entre les deux sources de données. À première vue, un important gain pourrait être constaté entre la canopée produite en 2015 par la ville de Montréal et celle produite par apprentissage profond en 2018. Il est ici nécessaire de considérer la capacité de l'apprentissage profond à identifier plus fidèlement la canopée et, également, que les données de 2018 sont en présence de feuilles. Il a toutefois été intéressant de constater que plusieurs boisés ont disparu dans cet arrondissement entre 2015 et 2018, mais que l'identification fine de la canopée est venue compenser cette perte. Il faut également noter que la canopée de Montréal 2015 contient quelques anomalies, surtout le long des rives de l'île. En effet, lorsque comparée avec le MNH, la délimitation de la canopée semble parfois suivre la rive plutôt que les arbres en surplomb (Figure 44), probablement lié à un découpage de la donnée avec des limites administratives. Ces anomalies ont été une source d'erreur lors de l'entraînement des modèles et a nécessité une sélection méticuleuse des données d'entraînements utilisées au début de l'apprentissage des modèles.

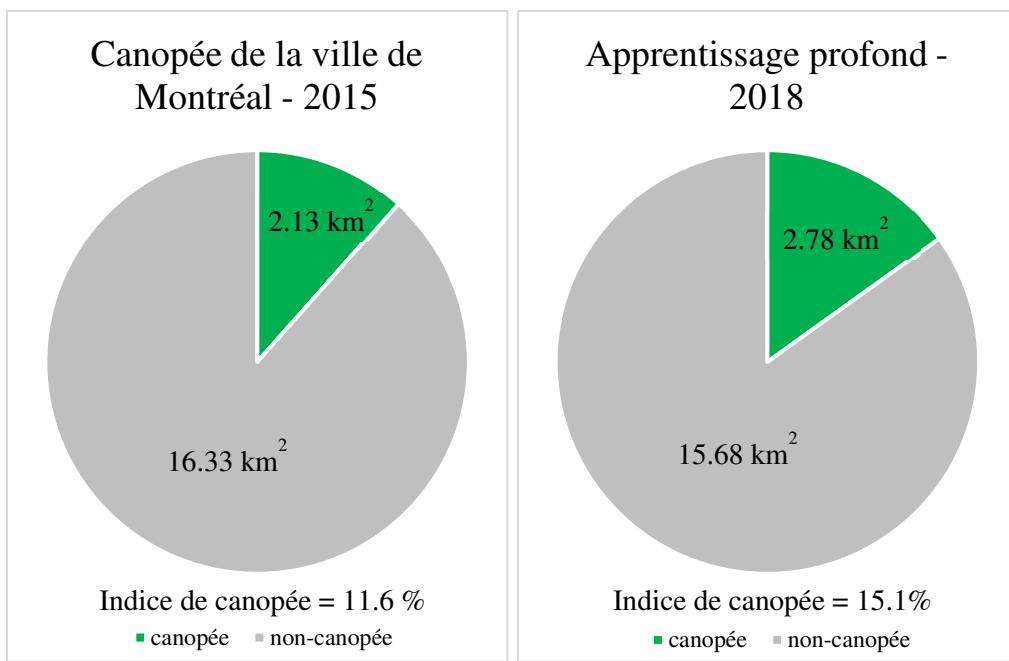


Figure 43. Comparaison de la superficie de canopée issue des données produites par la ville de Montréal et par ce projet utilisant l'apprentissage profond, pour l'arrondissement de Lachine à Montréal.

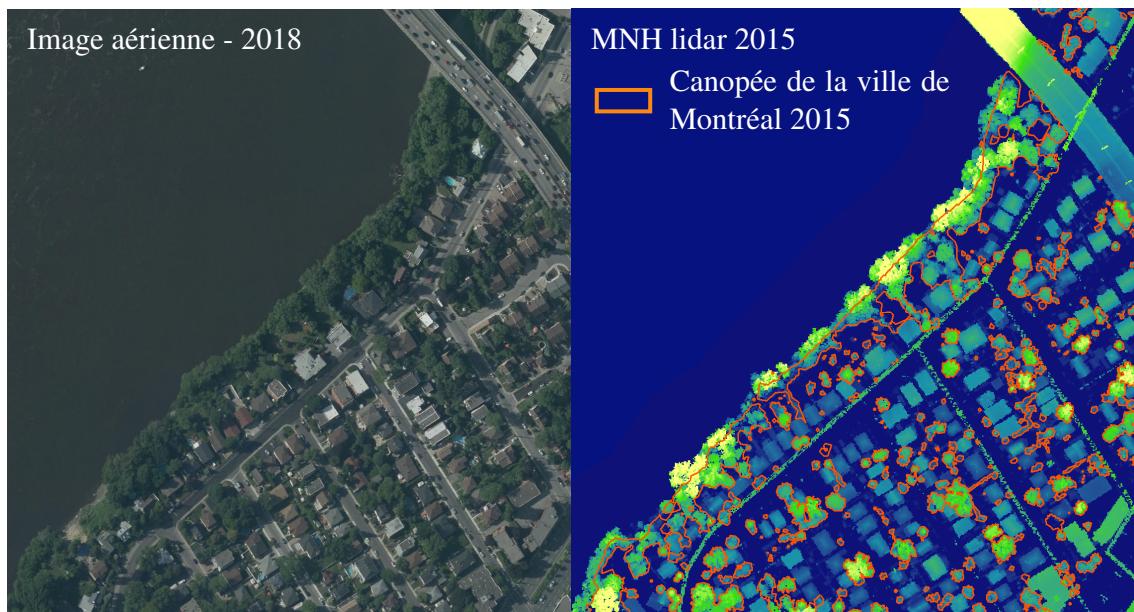


Figure 44. Illustration d'anomalies identifiées dans la canopée produite par la ville de Montréal en 2015 le long des rives.

## 6.8. Pistes d'amélioration

Une première piste d'amélioration serait de fournir en entraînement plus d'imagettes annotées manuellement et avec grande précision pour la canopée deux mètres et plus. En effet, il est à noter que l'algorithme utilisé n'a été entraîné qu'avec 600 imagettes annotées à deux mètres et plus, le reste étant des données synthétiques générées par apprentissage profond. Bien que cette technique se soit avérée performante, certaines omissions dans les haies et commissions dans les clôtures, barrages et véhicules récréatifs se sont transmises d'algorithme en algorithme par manque de données d'entraînement. Une annotation précise supplémentaire d'un certain nombre d'imagettes choisies spécifiquement dans des zones moins bien prédites permettrait à l'algorithme d'augmenter davantage sa précision de segmentation pour la canopée se trouvant entre deux et trois mètres.

Une seconde piste possible serait de fournir une donnée spectrale à l'algorithme pour l'aider à segmenter la canopée. Tout au long du projet, de nombreuses erreurs de commission ont été observées et corrigées grâce à de l'apprentissage actif telles que des cabanons, véhicules récréatifs, carrières ou industries. Cependant, une donnée spectrale aurait la capacité d'améliorer la distinction entre ces objets facilitant l'entraînement et permettant par conséquent d'obtenir de meilleures performances. Afin de créer cette donnée et de conserver un algorithme de détection n'utilisant que le lidar, la piste d'amélioration proposée serait de transformer l'intensité lidar en indice de végétation (p. ex. NDVI) pour l'ajouter comme quatrième variable en intrant de l'algorithme. Des algorithmes similaires de transfert de style par apprentissage profond ont déjà été utilisés pour transformer une image radar en rouge-vert-bleu (Ley, 2018), infrarouge en rouge-vert-bleu (Abbott *et al.*, 2020), créer un canal infrarouge d'une image rouge-vert-bleu (Uddin *et al.*, 2021) ou encore produire une donnée radar à partir d'une donnée lidar (Wang *et al.*, 2021).

La qualité des données lidar a une influence directe sur la superficie de la canopée identifiée. Les données lidar acquises avec feuilles sont beaucoup plus intéressantes et devraient être priorisées, cependant la planification de campagnes d'acquisition doit également tenir compte d'autres besoins nécessitant d'avoir des données lidar sans feuille. N'ayant pas de contrôle sur les dates d'acquisition des données lidar, une troisième piste d'amélioration visant à corriger le biais d'indice de canopée entre les données sans feuille et avec feuilles serait d'utiliser le même type d'algorithme de transfert de style, mais cette fois-ci pour transformer une donnée sans feuille en une donnée avec feuilles. Ce genre de transformation est déjà largement utilisé, par exemple, en conduite automobile assistée afin d'augmenter la robustesse des algorithmes aux différentes conditions routières (Li *et al.*, 2021). Cette solution pourrait également être utilisée à l'inverse, en transformant les données avec feuilles en données sans feuille, pour comparer les différentes données entre-elles à des moments distincts dans l'année.

## **7. Conclusion**

Le but de ce projet était l’élaboration d’une méthode automatique pour cartographier la canopée en utilisant une donnée relativement uniforme (lidar aéroporté) couvrant un très grand territoire (six RMR du Québec). Le modèle final montre d’excellentes performances de classification variable selon les RMR (précision globale entre 0,9559 et 0,9712 et coefficient de kappa allant de 0,8996 à 0,9393). Les indices de canopée prédits par RMR sont corrélés entre 97,5 et 99,6 % avec les indices calculés manuellement. Les prédictions réalisées par le modèle montrent une très bonne capacité de discernement des éléments présents, notamment en milieu urbain où une grande diversité de structures ressemble à de la végétation lorsqu’analysée uniquement avec des données lidar. Certaines erreurs ont toutefois été identifiées et concernent principalement des structures absentes des données d’ entraînement (p. ex. bateaux) ou des structures présentant fréquemment de la végétation sous-jacente (p. ex. câbles électriques). La cartographie de toutes les RMR avec cette méthode permet d’effectuer des comparaisons entre plusieurs secteurs intra et inter RMR. Des pistes d’amélioration ont été identifiées pouvant être appliquées à plusieurs stades du processus de développement, notamment par l’ajout d’algorithmes d’apprentissage profond afin de rendre plus uniforme ou améliorer les données lidar brutes utilisées. Lors de l’actualisation des données lidar de la province du Québec, une mise à jour de la canopée par cette méthode pourra être réalisée.

## 8. Références

- Abbott, R., Robertson, N. M., Martinez del Rincon, J. et Connor, B. (2020) Unsupervised object detection via LWIR/RGB translation. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), p. 407-415. Seattle, WA, USA : IEEE.
- Ahmad, M., Protasov, S. et Khan, A. (2017) Hyperspectral Band Selection Using Unsupervised Non-Linear Deep Auto Encoder to Train External Classifiers. ([url : https://www.researchgate.net/publication/317040484 Hyperspectral Band Selection Using Unsupervised Non-Linear Deep Auto Encoder to Train External Classifiers](https://www.researchgate.net/publication/317040484_Hyperspectral_Band_Selection_Using_Unsupervised_Non-Linear_Deep_Auto_Encoder_to_Train_External_Classifiers)), consulté le 25 février 2022.
- Bardes, A., Ponce, J. et LeCun, Y. (2021) VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning. CoRR, vol. abs/2105.04906.
- Bour, B., Genest, M.-A., Rashidfar, M. et Varin, M. (2021) Comparaison de méthodes de détection de chemins forestiers à partie d'imagerie satellitaire (Sentinel-2) : apprentissage automatique vs profond. (Technote No. 2021-03) (p. 5). CERFO.
- Cohen, J. (1960) A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, vol. 20, p. 37-46.
- Congalton, R. G. (1991) A review of assessing the accuracy of classifications of remotely sensed data. *Remote Sensing of Environment*, vol. 37, n°1, p. 35-46.
- Dong, X., Yu, Z., Cao, W., Shi, Y. et Ma, Q. (2020) A survey on ensemble learning. *Frontiers of Computer Science*, vol. 14, n°2, p. 241-258.
- Favarro, A., Raimundo-Costa, W., Anhê, A. C. B. M., Ferreira, D. C., Blanes-Vidal, V., dos Santos Senhuk, A. P. M., et others (2020) Influence of urban forest on traffic air pollution and children respiratory health. *Environmental monitoring and assessment*, vol. 192, n°3, p. 1-9.
- Genest, M.-A., Varin, M., Armellin, C. et Bour, B. (2021) Détection et dénombrement de monticules de plantation sur des images acquises par drone grâce à l'apprentissage profond. Centre d'enseignement et de recherche en foresterie de Sainte-Foy inc. (CERFO). Rapport 2021-23. 28 pages + 5 pages en annexe.
- Grilli, G. et Sacchelli, S. (2020) Health benefits derived from forest: A review. *International Journal of Environmental Research and Public Health*, vol. 17, n°17, p. 6125.
- Heisler, G. M. (2010) Urban forest influences on exposure to UV radiation and potential consequences for human health. *UV Radiation in Global Climate Change* (p. 331-369). Springer.
- Jingdong Wang, Ke Sun, Tianheng Cheng, Borui Jiang, Chaorui Deng, Yang Zhao, Dong Liu, Yadong Mu, Mingkui Tan, Xinggang Wang, Wenyu Liu, Bin Xiao, (2019)

Deep High-Resolution Representation Learning for Visual Recognition. Site internet (doi : arXiv:1908.07919v2)

- Kardan, O., Gozdyra, P., Misic, B., Moola, F. et Palmer, L. J. (2017) Neighborhood greenspace and health in a large urban center. *Urban Forests* (p. 77-108). Apple Academic Press.
- Kondo, M. C., Fluehr, J. M., McKeon, T. et Branas, C. C. (2018) Urban green space and its impact on human health. *International journal of environmental research and public health*, vol. 15, n°3, p. 445.
- Leboeuf, A., Pomerleau, I., et Québec (Province). Direction des inventaires forestiers (2015) Projet d'acquisition de données par le capteur LiDAR à l'échelle provinciale : analyse des retombées et recommandations.
- Lessard, G. et Boulfroy, E. (2008) Les rôles de l'arbre en ville (p. 21). Québec : Centre d'enseignement et de recherche en foresterie de Sainte-Foy inc. (CERFO).
- Ley, A. (2018) Exploiting GAN-Based SAR to Optical Image Transcoding for Improved Classification via Deep Learning.
- Li, X., Kou, K. et Zhao, B. (2021) Weather GAN: Multi-Domain Weather Translation Using Generative Adversarial Networks. arXiv:2103.05422 [cs].
- MacFaden, S. W., O'Neil-Dunne, J. P., Royar, A. R., Lu, J. W. et Rundle, A. G. (2012) High-resolution tree canopy mapping for New York City using LiDAR and object-based image analysis. *Journal of Applied Remote Sensing*, vol. 6, n°1, p. 063567.
- Maxwell, A. E., Warner, T. A. et Guillén, L. A. (2021) Accuracy Assessment in Convolutional Neural Network-Based Deep Learning Remote Sensing Studies—Part 1: Literature Review. *Remote Sensing*, vol. 13, n°13, p. 2450.
- Miller, J. R., White, H. P., Chen, J. M., Peddle, D. R., McDermid, G., Fournier, R. A., Shepherd, P., Rubinstein, I., Freemantle, J., Soffer, R. et LeDrew, E. (1997) Seasonal change in understory reflectance of boreal forests and influence on canopy vegetation indices. *Journal of Geophysical Research D: Atmospheres*, vol. 102, n°24, p. 29475-29482.
- Nowak, D. J., Hirabayashi, S., Bodine, A. et Greenfield, E. (2014) Tree and forest effects on air quality and human health in the United States. *Environmental pollution*, vol. 193, p. 119-129.
- R Development Core Team et Computing, R. F. for S. (2010) R: A Language and Environment for Statistical Computing (Vol. Vienna, Au). R Foundation for Statistical Computing.
- Roussel, J.-R., Auty, D., Coops, N. C., Tompalski, P., Goodbody, T. R. H., Meador, A. S., Bourdon, J.-F., de Boissieu, F. et Achim, A. (2020) lidR: An R package for analysis of Airborne Laser Scanning (ALS) data. *Remote Sensing of Environment*, vol. 251, p. 112061.
- Settles, B. (2009) Active Learning Literature Survey (p. 47).

- Statistiques Québec, (2021) Estimation de la population des régions métropolitaines de recensement (RMR), Québec, 1<sup>er</sup> juillet 2001 à 2021. Site internet (url : <https://statistique.quebec.ca/fr/document/population-et-structure-par-age-et sexe-rmr-regions-metropolitaines-de-recensement/tableau/estimation-population-regions-metropolitaines-recensement-rmr-quebec>), consulté le 10 février 2022.
- Timilsina, S., Aryal, J. et Kirkpatrick, J. B. (2020) Mapping Urban Tree Cover Changes Using Object-Based Convolution Neural Network (OB-CNN). *Remote Sensing*, vol. 12, n°18, p. 3017.
- Uddin, M. S., Hoque, R., Islam, K. A., Kwan, C., Gribben, D. et Li, J. (2021) Converting Optical Videos to Infrared Videos Using Attention GAN and Its Impact on Target Detection and Classification Performance. *Remote Sensing*, vol. 13, n°16, p. 3257.
- Varin, M. et Boulfroy, E. (2014) Calcul d'un indice de canopée pour le territoire de la ville de Québec (p. 55 p.). Centre d'enseignement et de recherche en foresterie de Sainte-Foy inc. (CERFO).
- Varin, M., Sena, G., Genest, M.-A., Armellin, C. et Dubois, A.-M. (2020a) Cartographie de l'indice de canopée 2020 de la ville de Québec par une classification orientée-objet ( No. Note technique 2020-02) (p. 6). Centre d'enseignement et de recherche en foresterie de Sainte-Foy inc. (CERFO).
- Varin, M., Sena, G., Genest, M.-A., Armellin, C. et Dubois, A.-M. (2020b) Cartographie de l'indice de canopée 2020 de la ville de Québec par une classification orientée-objet – Étude temporelle de l'indice de canopée (2015-2020) et comparaison de techniques de classification (Note technique 2020-02) (p. 4). Centre d'enseignement et de recherche en foresterie de Sainte-Foy inc. (CERFO).
- Ville de Montréal, (2022) Canopée 2015. Site internet (url : <https://donnees.montreal.ca/ville-de-montreal/canopee-2015>), consulté le 10 février 2022.
- Wang, J., Sun, K., Cheng, T., Jiang, B., Deng, C., Zhao, Y., Liu, D., Mu, Y., Tan, M., Wang, X., Liu, W. et Xiao, B. (2020) Deep High-Resolution Representation Learning for Visual Recognition. arXiv:1908.07919 [cs].
- Wang, L., Goldluecke, B. et Anklam, C. (2021) L2R GAN: LiDAR-to-Radar Translation. In H. Ishikawa, C.-L. Liu, T. Pajdla, et J. Shi (dir.), *Computer Vision – ACCV 2020, Lecture Notes in Computer Science* (Vol. 12624, p. 704-720). Cham : Springer International Publishing.
- Zhang, Q., Yang, L. T., Chen, Z. et Li, P. (2018) A survey on deep learning for big data. *Information Fusion*, vol. 42, p. 146-157.